Групповой проект №1

Exploratory Data Analysis

Выполнили:
Алышов Виталий ББИ2402
Глодя Мария ББИ2402
Мерцалов Владимир ББИ2402
Якушина Анна ББИ2402

План проекта

01 Обзор исходных данных

02 Очистка данных

03 Обогащение датасета

04 Анализ данных

05 Выводы для бизнеса

Цель исследования: анализ качества контента Netflix (фильмов и сериалов) и принципов его оценки пользователями с использованием данных о жанрах, рейтингах и объеме выпуска, для выявления зон роста и стратегических направлений развития компании

1. Обзор исходных данных

1000 Netflix Shows

1000
значений

496
уникальных шоу

- Данный датасет “1000 Netflix Shows” содержит информацию о шоу, представленных на платформе Netflix (фильмы и сериалы). Признаки представлены в таблице справа.
- Данные были опубликованы пользователем на платформе Kaggle в 2017 году.
- Датасет был создан пользователем с целью проанализировать и понять рейтинговое распределение шоу Netflix.

Признак	Описание
title	название шоу
rating	рейтинг шоу
ratingLevel	описание рейтинговой группы и особенностей шоу
ratingDescription	рейтинг шоу, закодированный числом
release year	год выпуска шоу
user rating score	оценка пользователей
user rating size	общий рейтинг пользователей

2. Очистка данных

01 Удалили столбцы ratingLevel, user rating size

02 Удалили пропуски

03 Убрали дубликаты

Дубликаты

Вместо того, чтобы добавить 1000 шоу вручную, создатель датасета использовал следующий алгоритм:

1. Взял 4 шоу из 4 различных рейтингов: G, PG, TV-14, TV-MA (итого получив 16 уникальных шоу)
2. Для каждого из этих шоу взял по 53 рекомендованных Netflix’ом шоу
3. Полученный перечень шоу содержал дубликаты в связи с тем, что рекомендательная система скорее всего предложила одни и те же шоу для стартовых позиций.

3. Обогащение датасета

01

Добавили датасет IMDb

02

Добавили датасет
с номинантами
и победителями премии
“Эмми”

03

Создали два
дополнительных датасета:
с режиссерами и странами

User rating score — нужен ли?

Отдельное внимание стоит уделить столбцу **user rating score.** В 2017 году Netflix **сменил** систему пятизвездочного оценивания на систему “палец вверх - палец вниз”, после чего появился percent match рядом с фильмами.

Для определения корреляции user rating score и averageRating мы построили диаграмму рассеяния. Из хаотичного расположения точек на диаграмме можно заключить, что **выраженной зависимости** между рейтингом IMDb **нет**.

Это подтверждает, что пользовательская оценка Netflix формируется на основе индивидуальных предпочтений зрителя, а не общего мнения.

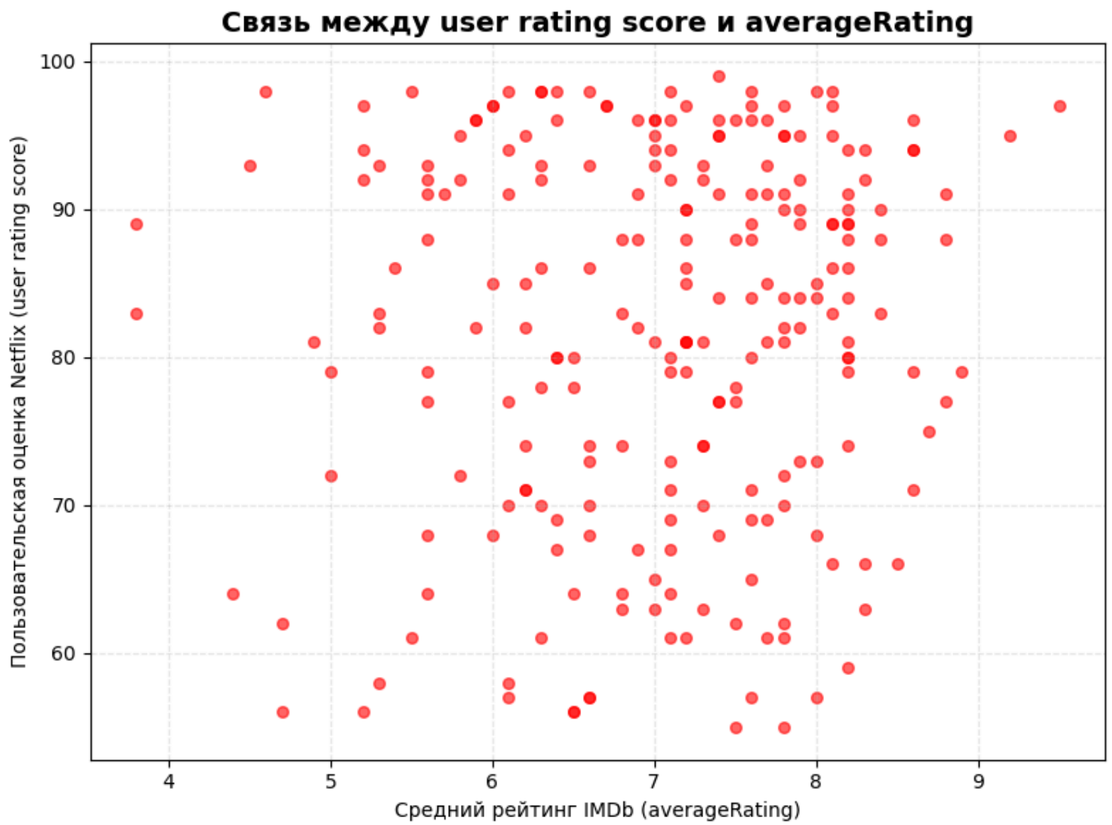

Анализ оценок пользователей

Большинство зрителей ставят фильмам оценки в диапазоне от 6 до 8 баллов.
Крайние значения — как низкие (0–4), так и очень высокие (9–10) — встречаются значительно реже.
Такое распределение отражает естественную тенденцию аудитории оценивать контент немного выше среднего уровня.

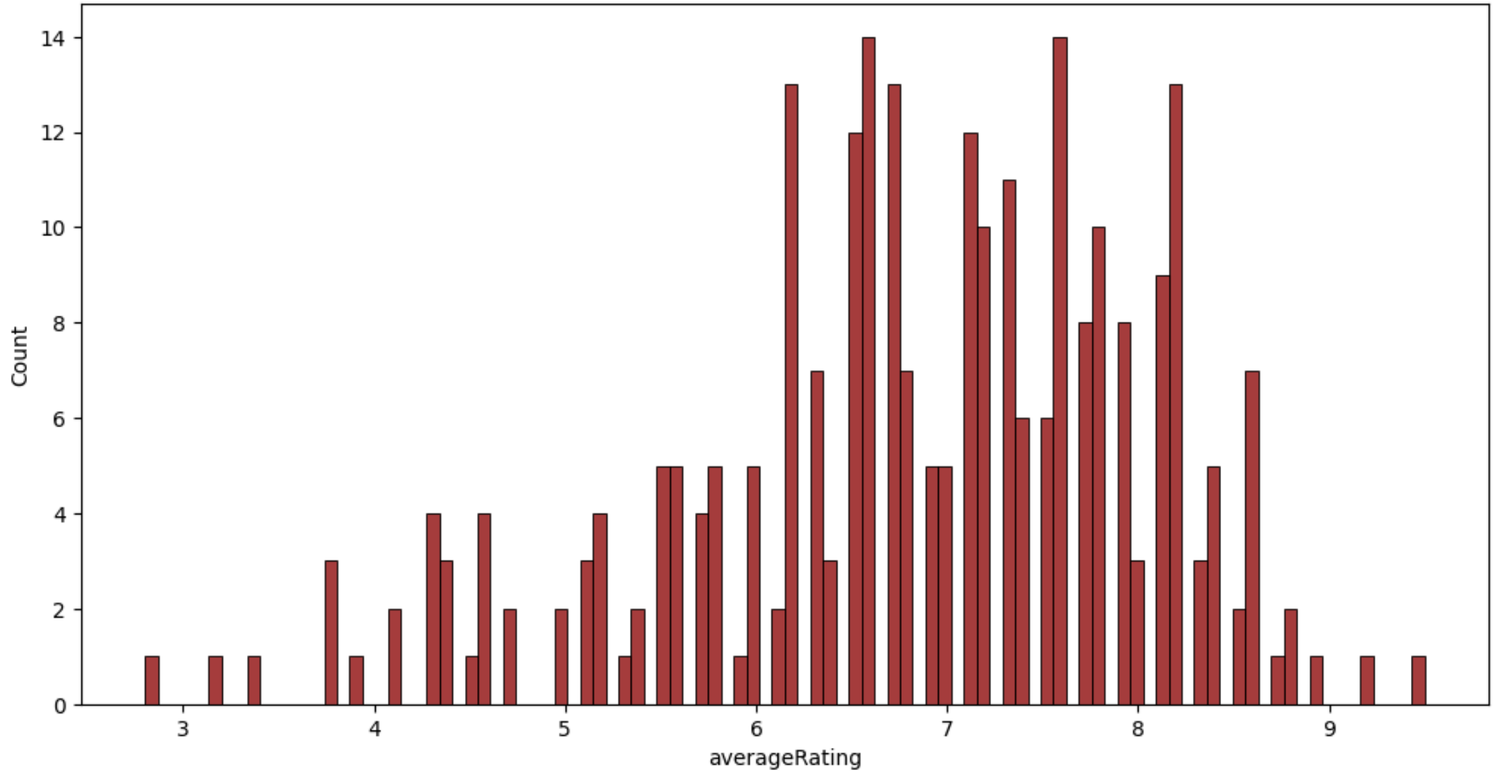


```
stats = extra_data_countries['averageRating'].describe()
extra_data_countries['averageRating'].median() #медиана = 7
stats
```

	averageRating
count	274.000000
mean	6.822263
std	1.217748
min	2.800000
25%	6.200000
50%	7.000000
75%	7.700000
max	9.500000

Анализ рейтинговых групп

1. **G (General Audiences)** — нет возрастных ограничений
2. **NR (Not Rated)** — фильм, не получивший рейтинг Американской ассоциации
3. **PG (Parental Guidance Suggested)** — рекомендуется присутствие родителей
4. **PG-13 (Parents Strongly Cautioned)** — детям до 13 лет просмотр не желателен
5. **R (Restricted)** — лицам до 17 лет обязательно присутствие родителя либо законного представителя
6. **TV-14 (Parents Strongly Cautioned)** — настоятельное предостережение родителям
7. **TV-G (General)** — широкая аудитория (аналог G)
8. **TV-MA (For Mature Audiences)** — только для взрослой аудитории
9. **TV-PG (Parental Guidance Suggested)** — просмотр с разрешения родителей (аналог PG)
10. **TV-Y (Young)** — для детей любого возраста
11. **TV-Y7 (Young above 7)**— для детей старшего возраста
12. **TV-Y7-FV (Young above 7 + Fantasy Violence)** — для детей старшего возраста (есть сцены насилия над фантастическими героями)
13. **UR (Unrated)** — возрастное ограничение не присвоено (расширенные версии фильмов могут содержать контент, отличающийся от релиза в кинотеатрах, и могут быть неподходящими для несовершеннолетних)

13

рейтинговых групп представлено в датасете

Анализ рейтинговых групп

Посмотрим, как фильмы распределены по рейтинговым группам. Заметим, что распределение является неравномерным: существенно преобладает контент с рейтингом **TV-14** (для подростков) и **TV-MA** (только для взрослой аудитории).

Рейтинговые группы

Мы легко можем оценить, какие возрастные ограничения были оценены выше в каждый год, однако изменение среднего рейтинга конкретного возрастного ограничения с течением времени затруднительно. Рассмотрим отдельные графики:

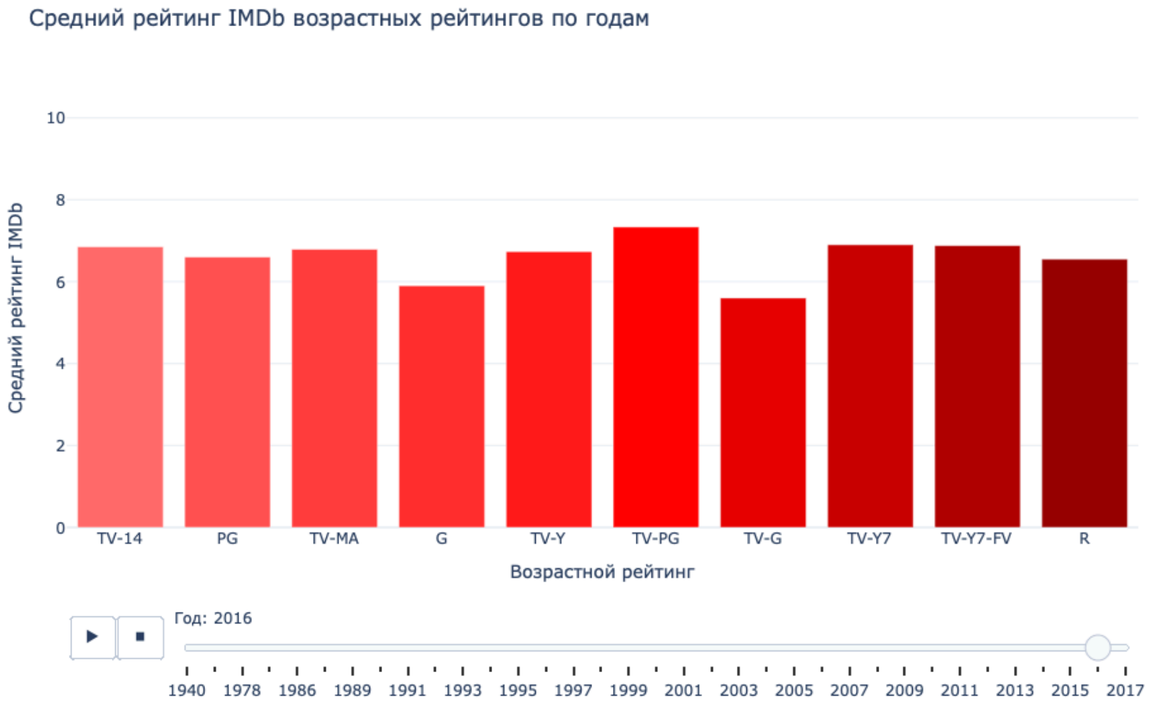

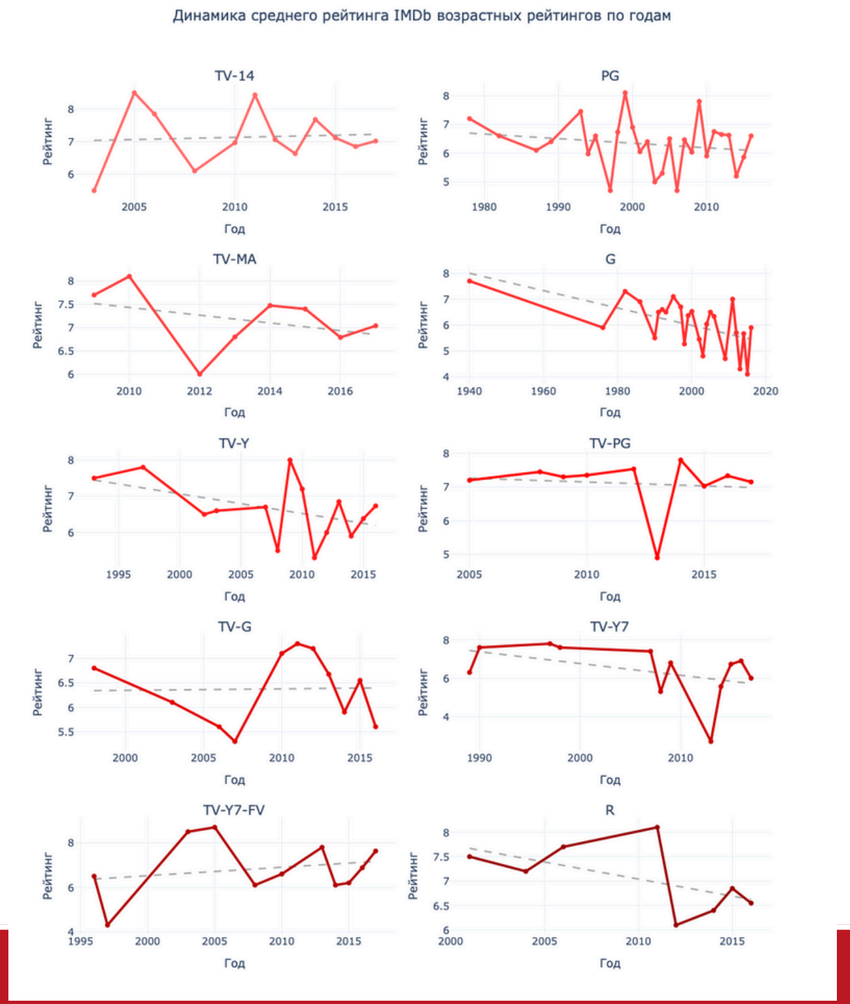

Можем заметить, что рейтинг каждого из возрастного ограничения меняется практически хаотично. Из этого можем сделать вывод, что расчитывать на успех шоу только из-за его ограничения аудитории в долгосрочной перспективе - нельзя.

Анализ длительности фильмов

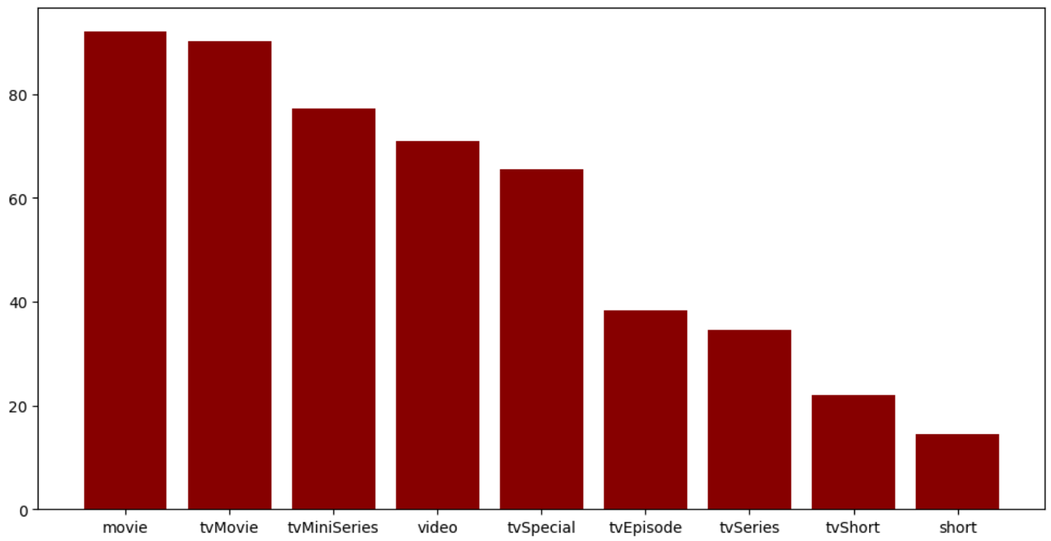

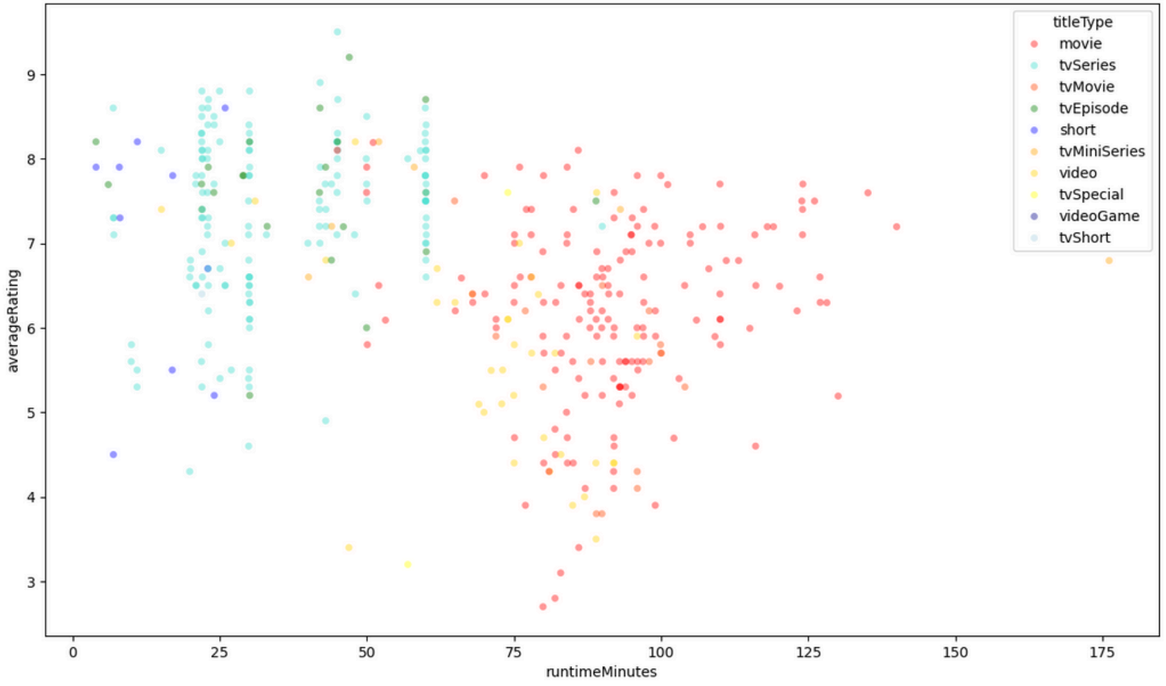

Большинство сериалов короче 60 минут.
В среднем типы контента с меньшим средним временем воспринимаются лучше. Однако в рамках одного типа контента бОльшая длительность часто приводит к лучшему результату.

Фильмы vs сериалы

На первый взгляд кажется, что фильмов больше, чем сериалов. Рассмотрим, что из себя представляют малочисленные типы контента:
К фильмам можем отнести еще tvmovie,
К сериалам можем отнести еще tvseries, tvminiseries, tvepisode, tvspecial.
Тогда распределение получится следующим:

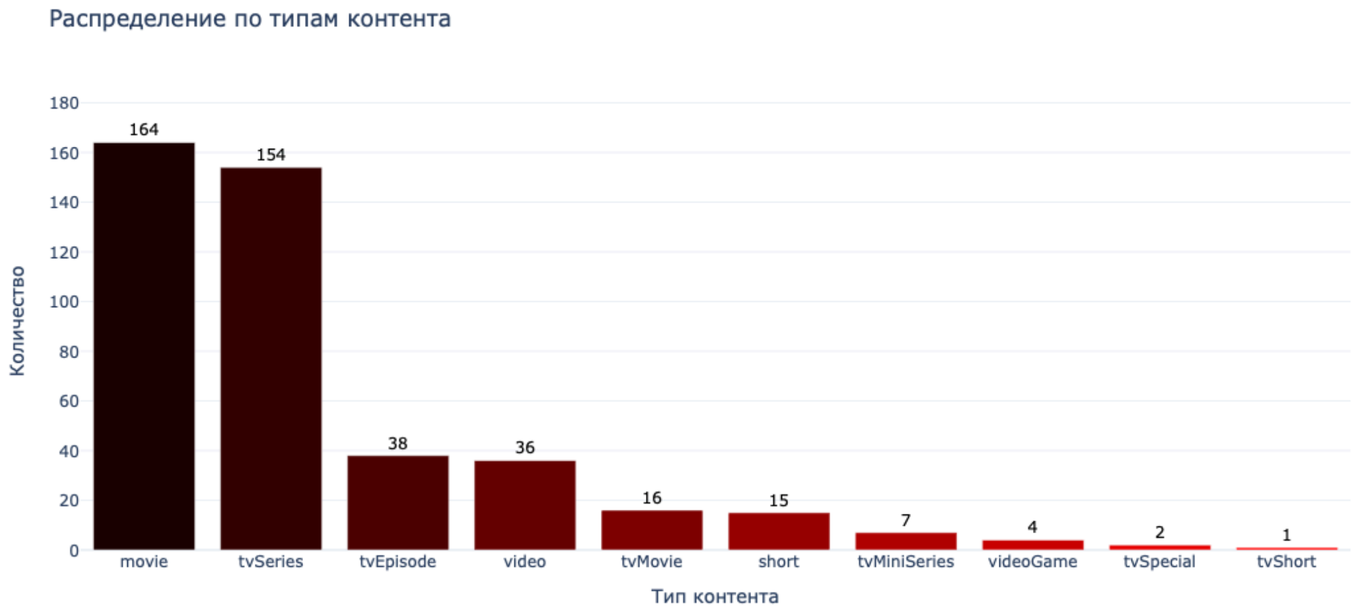

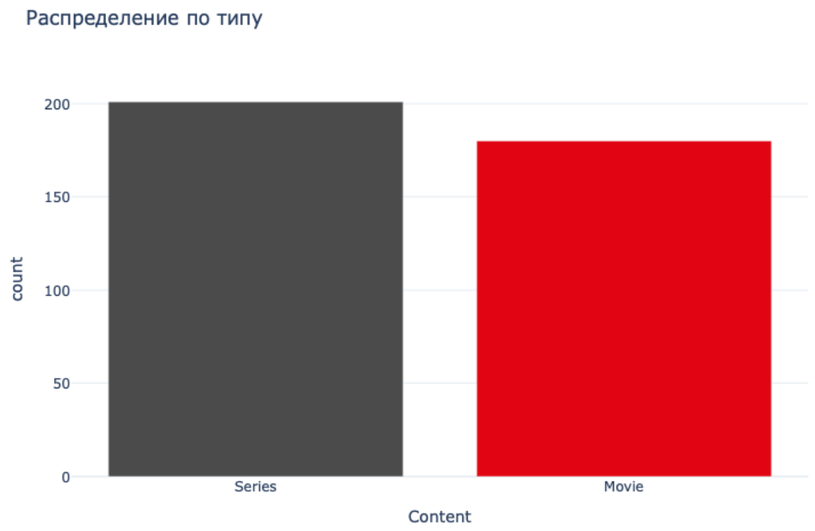

Динамика распределения фильмов по жанрам

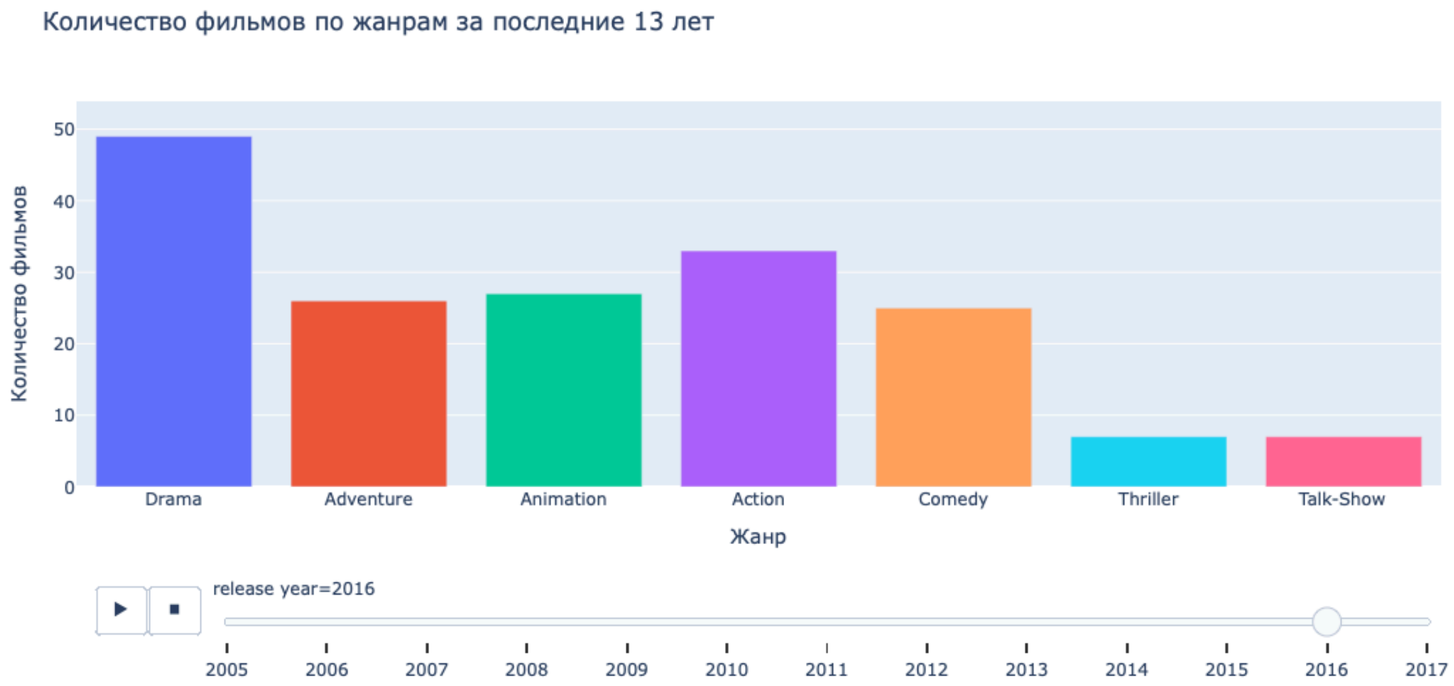

С течением времени заметен рост доли жанров «Drama», «Comedy» и «Action».
Это может свидетельствовать о фокусе Netflix на наиболее массовых жанрах, но также указывает на недооценённые ниши, вроде «Documentary» и «History», где при относительно малом объёме производства наблюдаются высокие рейтинги.
Инвестиции в такие ниши могут повысить общую зрительскую лояльность.

Фильмы vs сериалы

Наша следующая гипотеза заключается в том, что рейтинг может зависеть от жанра тайтла. Рассмотрим топ 15 самых многочисленных жанров:

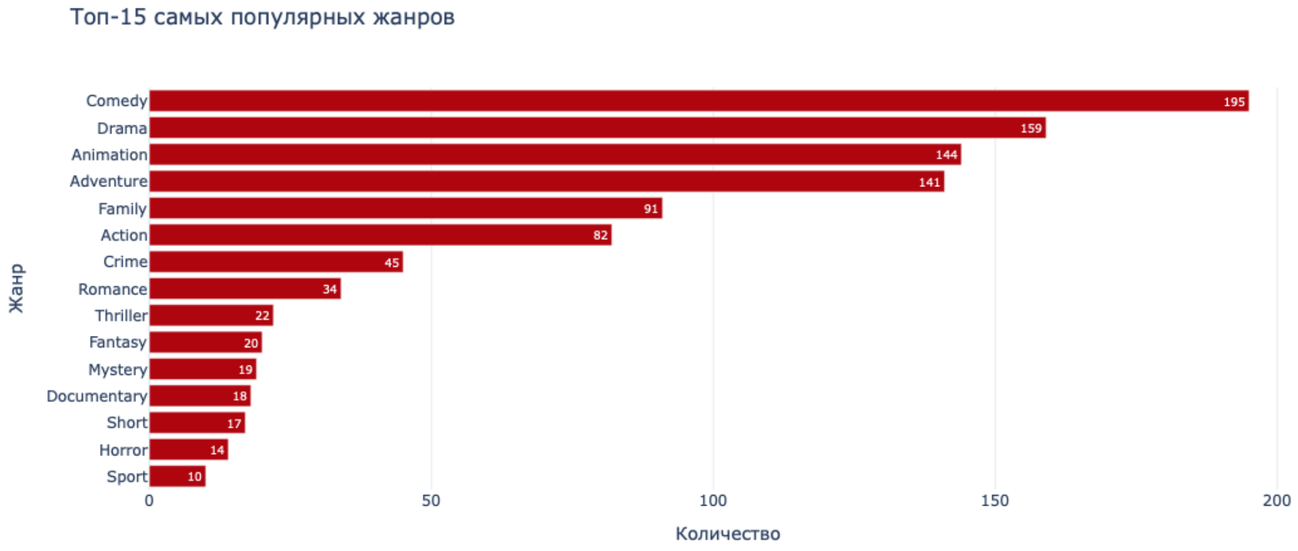

Среди тайтлов всех типов самыми популярными жанрами являются комедии и драмы. Посмотрим распределение еще и по двум основным типам тайтлов:

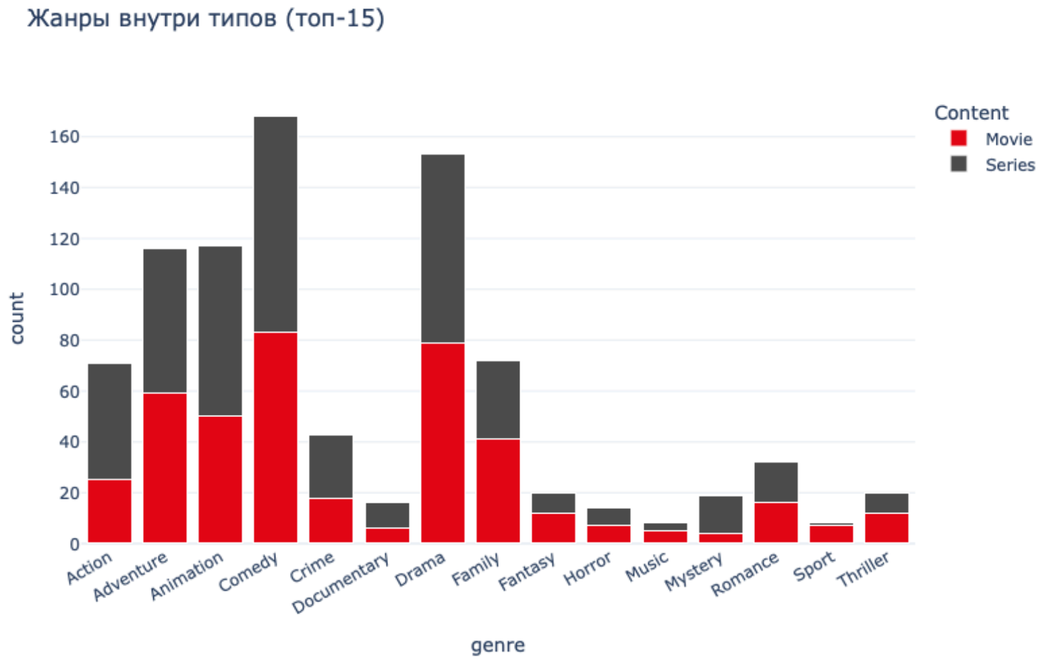

Фильмы vs сериалы

Рассмотрим, как менялись средние рейтинги жанров с течением времени

Заметим, что рейтинги нестабильны и постоянно меняются.
Сложно выделить постоянный рост/снижение рейтинга отдельных жанров динамике, так как не во все годы выпускались фильмы всех жанров. Тогда рассмотрим графики изменения рейтинга жанров по отдельности.

Действительно, по большей части рейтинг жанров меняется хаотично, однако в последние 3 года наблюдается тенденция на рост среднего рейтинга тайтлов жанров Animation, Adventure, Family и Action.

Фильмы vs сериалы

Рассмотрим теперь распределение среднего рейтинга IMDB в топ 15 жанров по численности (в остальных представлено слишком мало данных, чтобы отслеживать общие тенденции)

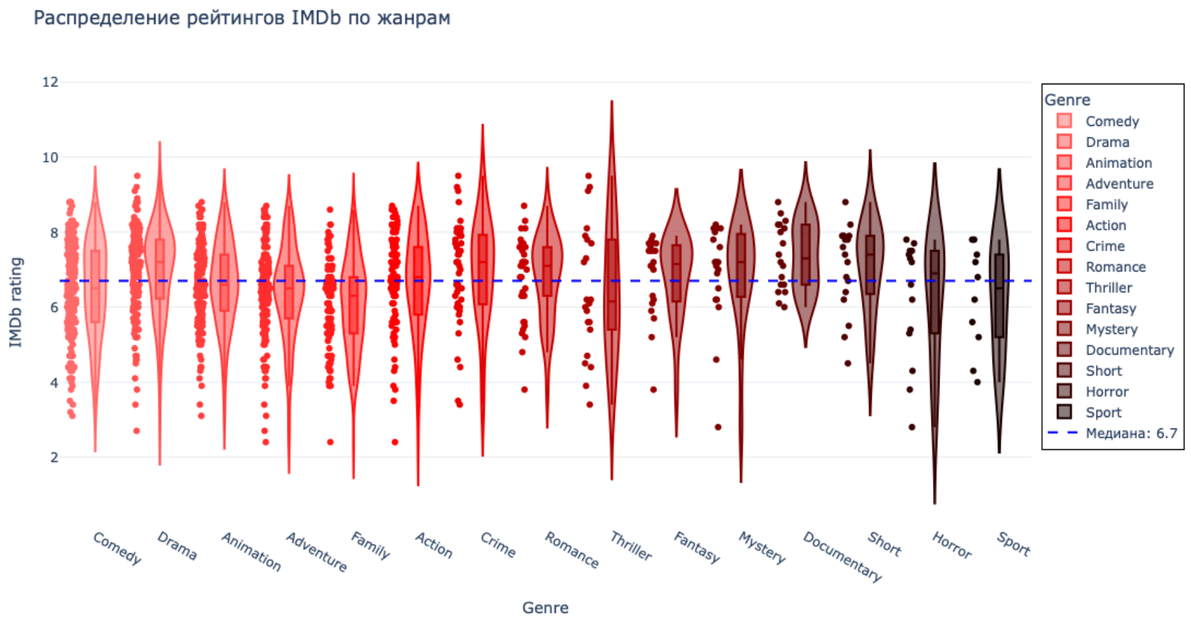

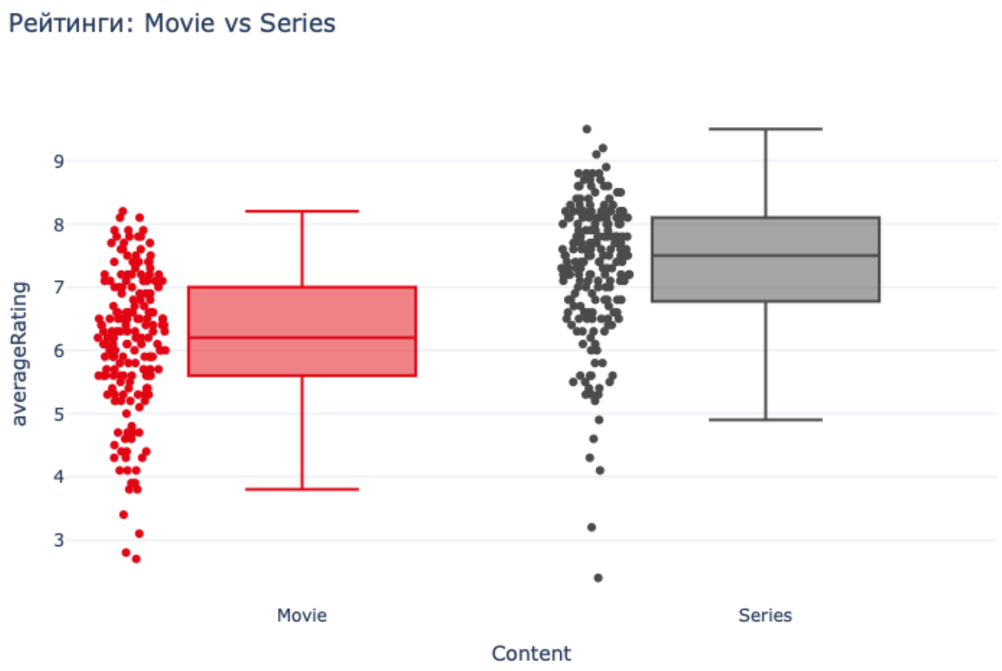

Можем заметить, что у немногочисленных жанров (например, Документальные тайтлы), достаточно часто встречается высокий средний рейтинг.

Фильмы vs сериалы

Жанры History, Biography и Documentary получают самые высокие оценки зрителей, но представлены на платформе в небольшом количестве.
Netflix может использовать это как возможность увеличить долю таких фильмов и тем самым повысить интерес аудитории.

Среди сериалов жанры Biography и Sci-Fi демонстрируют высокие рейтинги, но их представлено немного.
Инвестиции в развитие таких направлений могут стать для Netflix источником значительной выгоды.

Анализ распределения запущенных шоу по годам

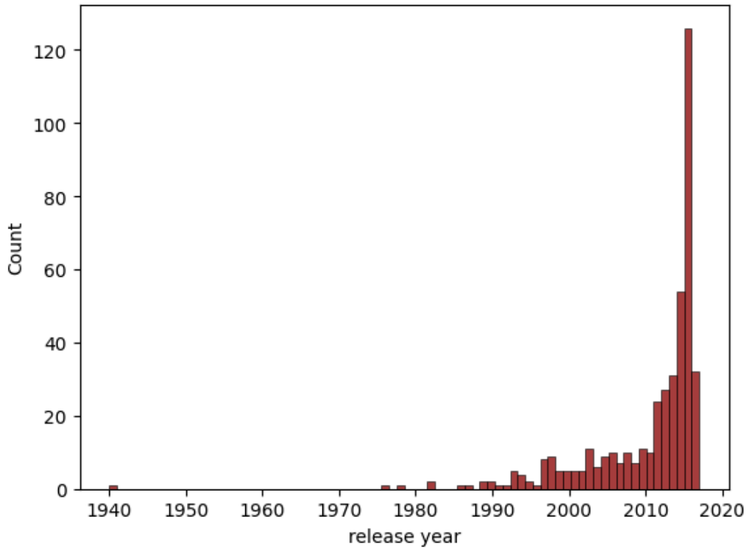

Наблюдается устойчивый рост количества выпущенных шоу в последние годы, что отражает общую стратегию Netflix по расширению библиотеки контента.

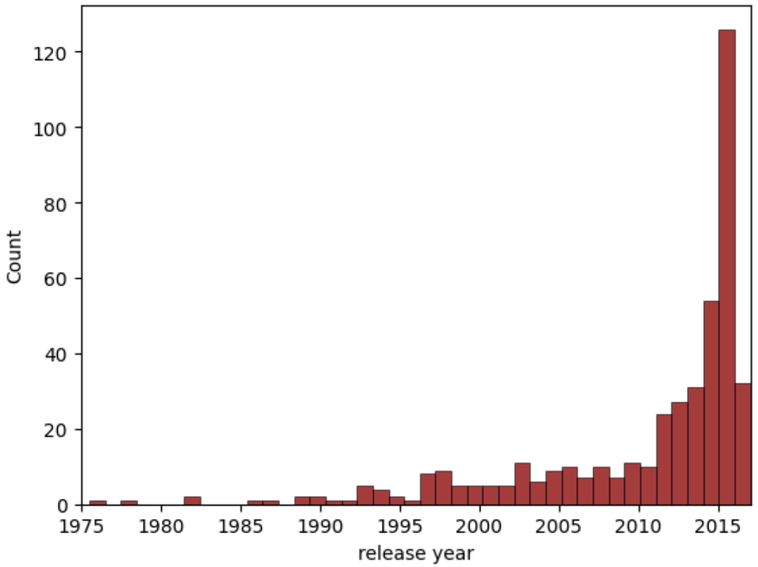

Анализ количества фильмов по странам

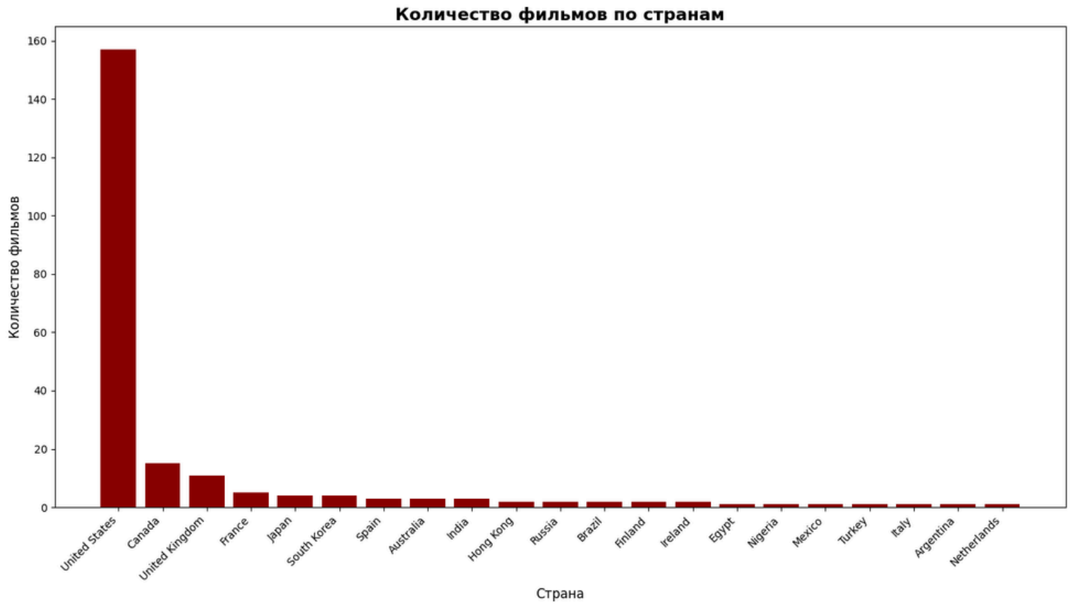

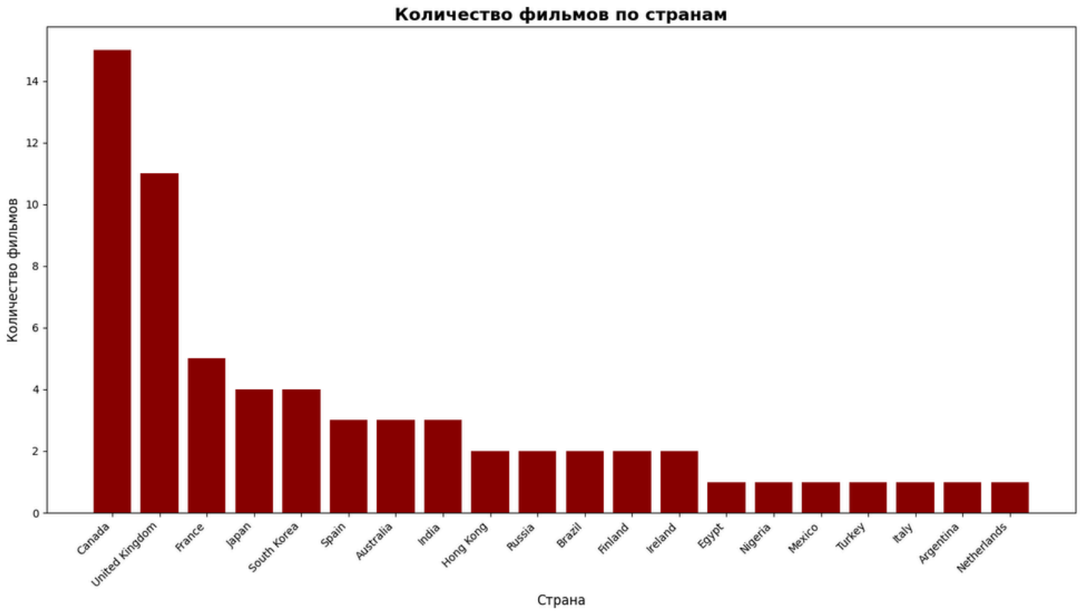

Большинство фильмов производятся в англоязычных странах

Анализ средних оценок по странам

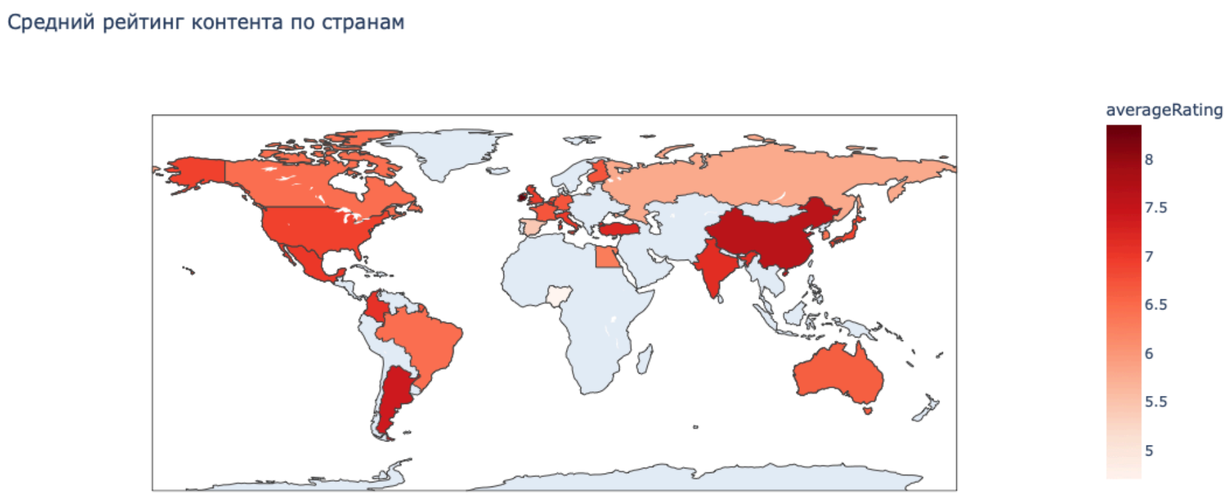

В странах с большим числом фильмов средний рейтинг приближен к середине шкалы рейтинга. В странах с маленьким числом фильмов средний рейтинг приближен к верхней/нижней границе.

Анализ режиссеров

Рассмотрим теперь топ-15 режиссеров с самым высоким средним рейтингом IMDb их работ.

Можно заметить, что у ряда режиссеров, даже с относительно небольшим количеством проектов, средний рейтинг их фильмов стабильно высокий.

Для компании Netflix это может быть сигналом: сотрудничество с такими режиссерами потенциально выгодно — их контент чаще получает признание зрителей и формирует положительный имидж платформы.

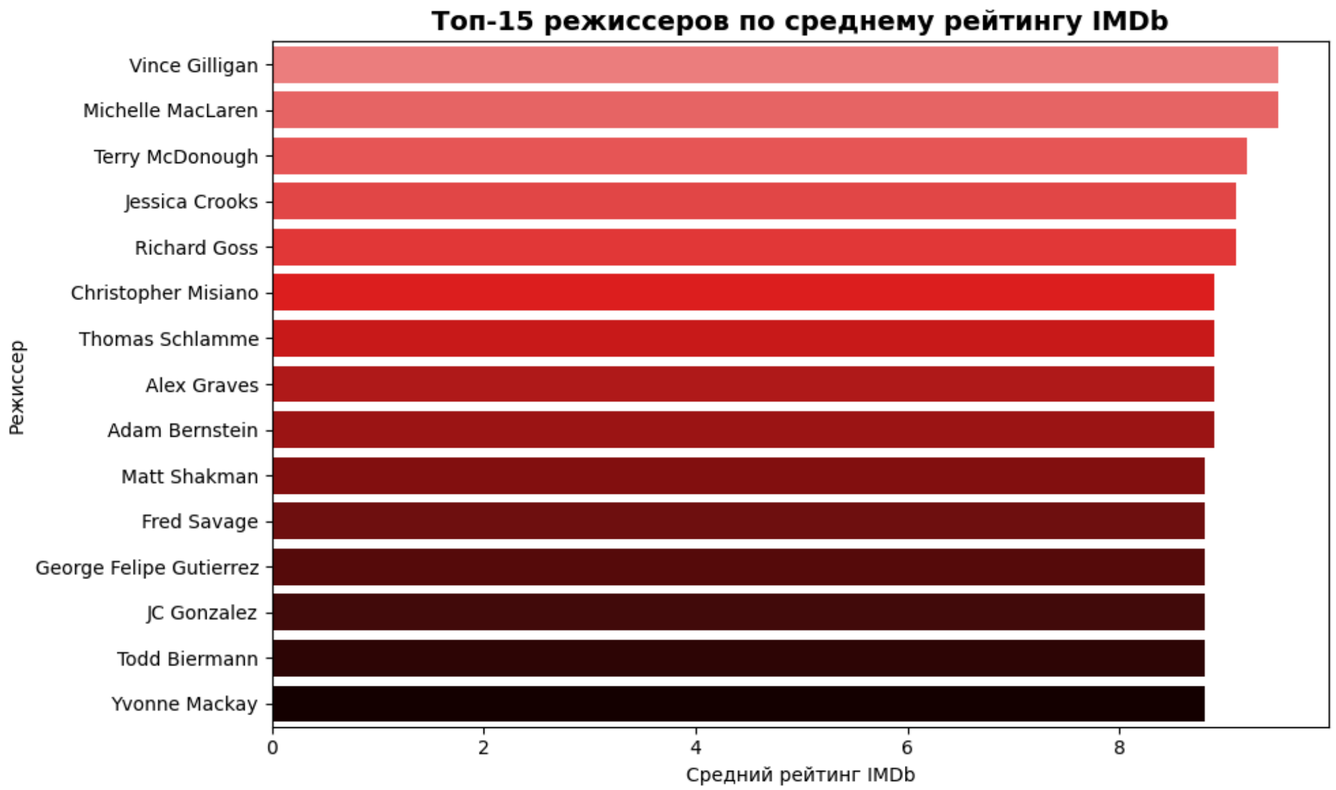

Анализ номинантов и победителей премии “Эмми”

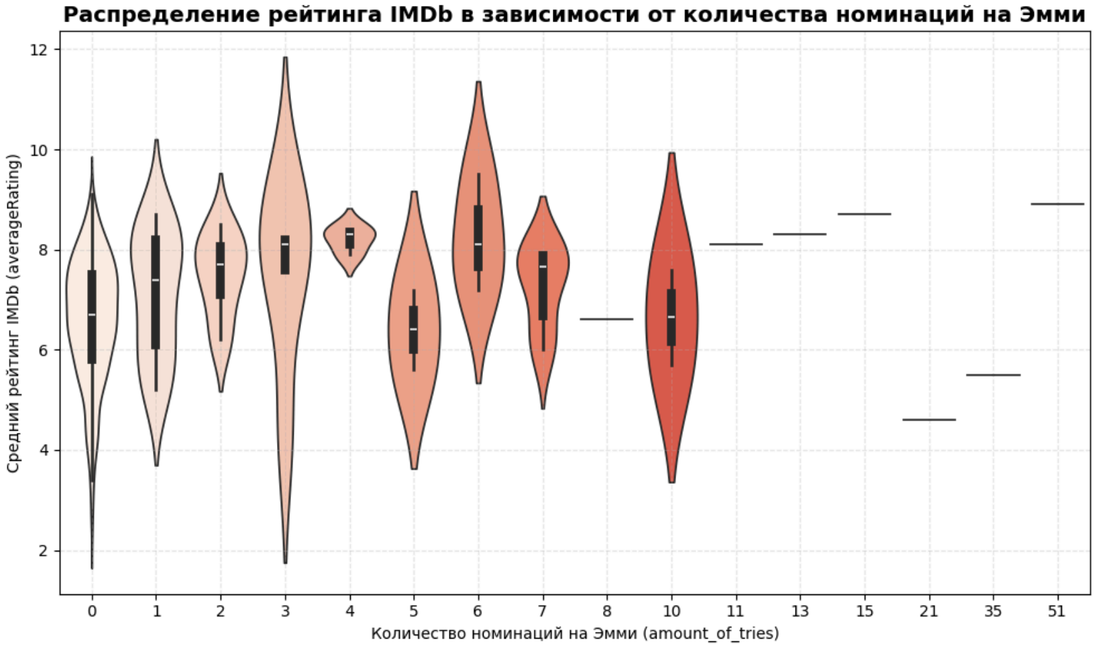

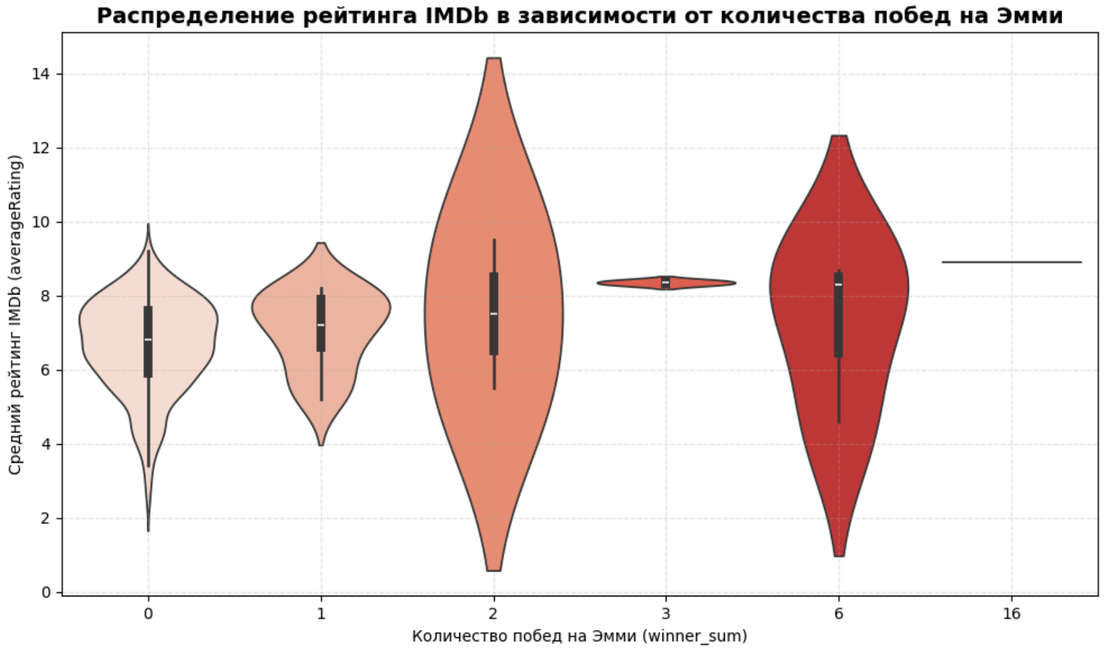

Фильмы без номинаций чаще имеют рейтинги 6–7. По мере увеличения количества номинаций распределение смещается к 7.5–8+. Фильмы без побед имеют широкий разброс рейтингов — от средних до высоких. С ростом числа побед распределение сдвигается к высоким рейтингам (7.5–8.5). У победителей с несколькими наградами разброс меньше — почти все с высоким рейтингом.

Выводы для бизнеса

- Большинство представленного контента относится к возрастным категориям **TV-14** и **TV-MA**, что говорит о востребованности материалов, рассчитанных на подростковую и взрослую аудиторию. Netflix целесообразно и дальше уделять основное внимание этим категориям, поскольку именно они охватывают наиболее широкую часть зрителей платформы.
- В среднем **сериалы** на Netflix получают более **высокие оценки**, чем фильмы. Это означает, что пользователи чаще положительно реагируют на сериальный (короткий) формат, однако более сериалы с более длительными эпизодами оцениваются выше. Таким образом, компании целесообразно увеличивать долю сериалов, однако сделать акцент на большей продолжительности отдельных серий. Также Netflix стоит обратить внимание на структурирование контента так, чтобы удерживать внимание зрителя без избыточного растягивания повествования.
- Жанры History, Biography, Documentary и Sci-Fi показывают самые высокие средние рейтинги, но представлены на платформе в ограниченном количестве. Расширение ассортимента в этих нишах может повысить зрительскую удовлетворенность и привлечь новую аудиторию, ориентированную на более интеллектуальный и содержательный контент.
- Фильмы и сериалы, получившие номинации или победы на премии **“Эмми”**, демонстрируют заметно **более высокие** средние рейтинги. Это подчеркивает ценность контента, признанного критиками. Награды повышают не только зрительское доверие, но и репутационную привлекательность бренда.
- Анализ средних рейтингов режиссеров выявил несколько **постановщиков с высокими оценками** их фильмов. Netflix может использовать эти данные при планировании партнерств и закупке контента: сотрудничество с такими режиссерами повышает вероятность коммерческого успеха и позитивного восприятия новых проектов.
- В некоторых странах наблюдается крайне высокий средний рейтинг при малом количестве выпуска фильмов. Для компании релевантно обратить внимание на инвестиции в фильмы из стран с высоким рейтингом, таких как Ирландия и Аргентина.
- За последние 3 года наблюдается тенденция стабильного роста среднего рейтинга жанров Animation, Adventure, Family и Action. Компания может инвестировать в покупку прав на фильмы этих жанров.

Выводы для бизнеса

Общий стратегический вывод:
Netflix следует делать акцент на качественном и премиальном контенте, уделяя особое внимание:

- развитию сериалов и коротких форматов,
- продвижению жанров с высоким рейтингом (History, Biography, Documentary, Sci-Fi),
- сотрудничеству с успешными режиссерами

Такой подход позволит платформе повысить удовлетворенность аудитории, укрепить бренд как поставщика качественного видеоконтента и максимально эффективно использовать инвестиции в производство и закупку фильмов и сериалов.