Групповой проект №2

DE: SCRAPING & API

Выполнили:
Азаров Александр ББИ2402
Алышов Виталий ББИ2402
Глодя Мария ББИ2402
Мерцалов Владимир ББИ2402
Морев Егор ББИ2402
Якушина Анна ББИ2402

План проекта

1. Рассмотреть волатильный и развивающийся сектор экономики (IT), зависимый от новостей. Выбрать первую компанию для рассмотрения.

2. Собрать акции выбранных компаний и цен альтернативых активов (золото, серебро, биткоин, нефть)

3. Собрать новости методом парсинга для выбранной компании + собрать новости через API/RSS о самой компании и о других компаниях отрасли

4. Разбить новости на 6 типов

5. Разведочный анализ данных и оценка влияния каждого типа новости

Цель исследования - подготовить инвестиционные рекомендации для трейдера, на основании чувствительности котировок акций по отношению к новостям.

О специфике постановки задачи

Новостные издания помимо значимых событий публикуют новости-шумы, которые никак не влияют на стоимость. Следовательно стоило бы оценить значимость влияния новостей на акции компаний

- Абсолютное большинство новостных изданий не позволяют парсить себя, в силу конкуренции новостных изданий
- Парсинг занимает значительно больше времени, относительно API
- API сервисы по сбору новостей часто работают некорректно, имеют малые лимиты, собирают не все новости

Категории новостей

1 Regulatory - новости о взаимоотношении компании с государствами- судебные дела, госзакупки, ограничения и тд
2. Financial - новости о публикации отчетности компании, положении дел в ней, привлечение инвестиций
3. Controversies - имиджевые новости компании
4. Deals - новости о сделках компании - покупки стартапов, инвестиции в инфраструктуру, слияния
5. Products - новости о релизах новых продуктов, успехи текущих продуктов
6. Competitors - новости о конкурентах, об их успехах и запусках.

Сбор данных: API

Макроэкономические параметры (золото и проч)

Стоимость акций 6ти компаний: Nvidia, Google, Meta, Microsoft, Oracle, Palantir

Стоимость альтернативных активов: золото, биткоин, серебро, биткоин, валюты и тд

Обзор данных: RSS

Мы начали со сбора новостей через API, однако они работали некорректно

Поэтому мы сделали выбор в пользу RSS - он содержал больше новостей, не имел лимитов, позволял более гибкую настройку.

В результате мы получили 36 датасетов с новостями для каждого типа новости и компании

Обзор данных: NVIDIA

Получено 10000+ записей с новостями за период с конца 2021 года по настоящее время.

Было выделено **6** типов категорий, которые потенциально могут влиять на рынок. Были составлены словари содержащие кортежи ключевых слов для каждой категории, каждое слово из которых имеет определенный вес, далее рассматривается сумма весов по каждой из категорий.

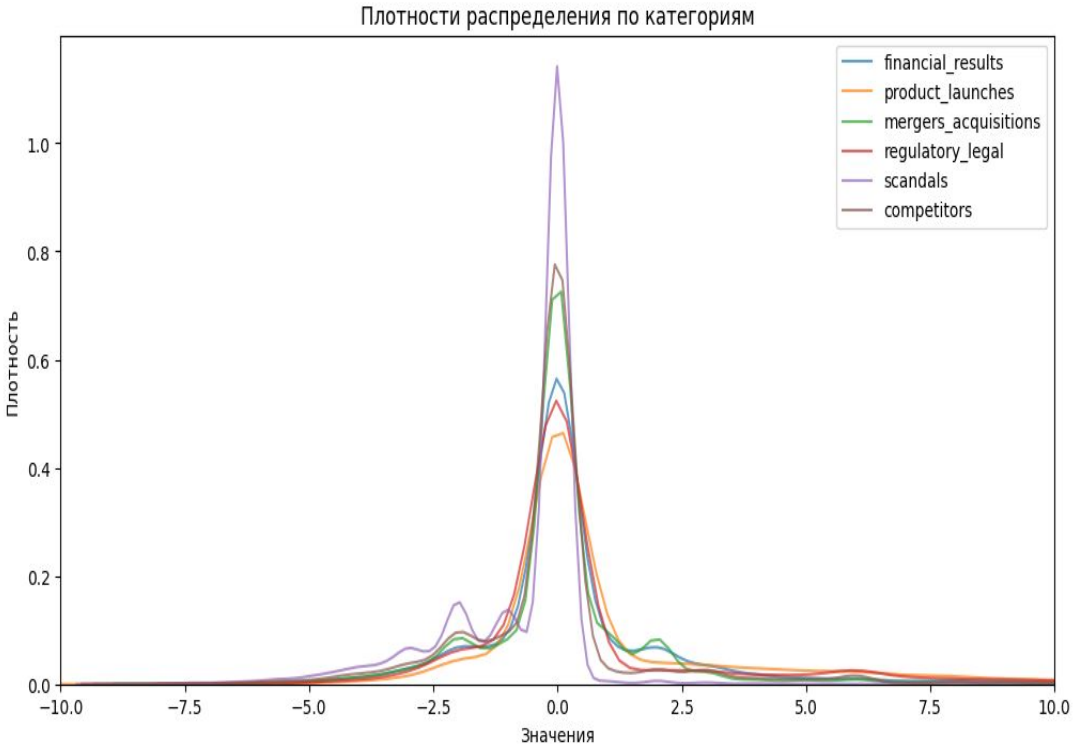

Выделение наиболее значимых новостей

с учетом специфики категории

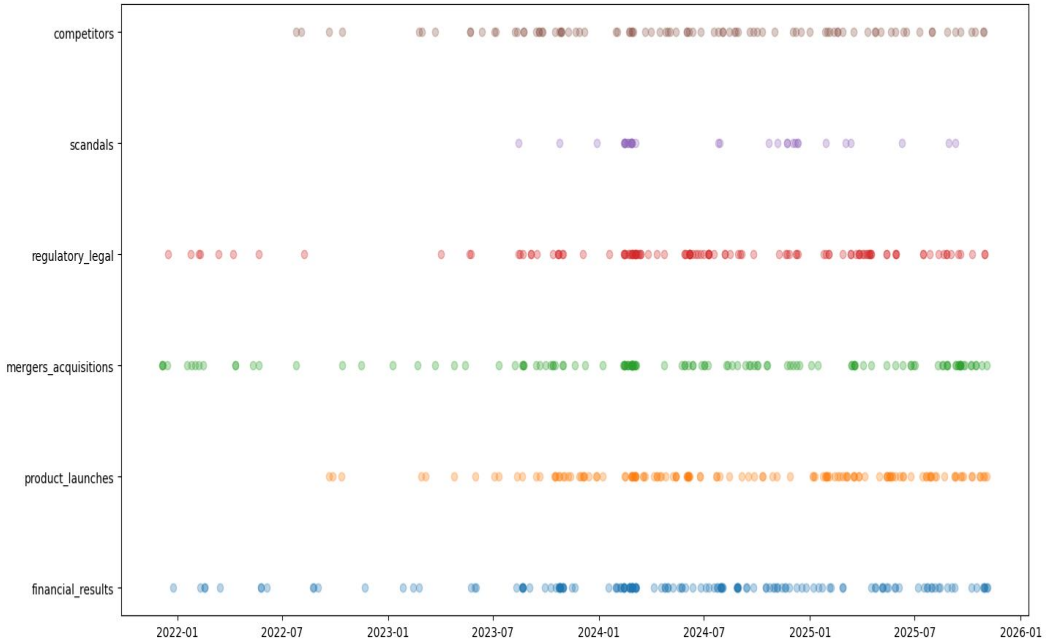

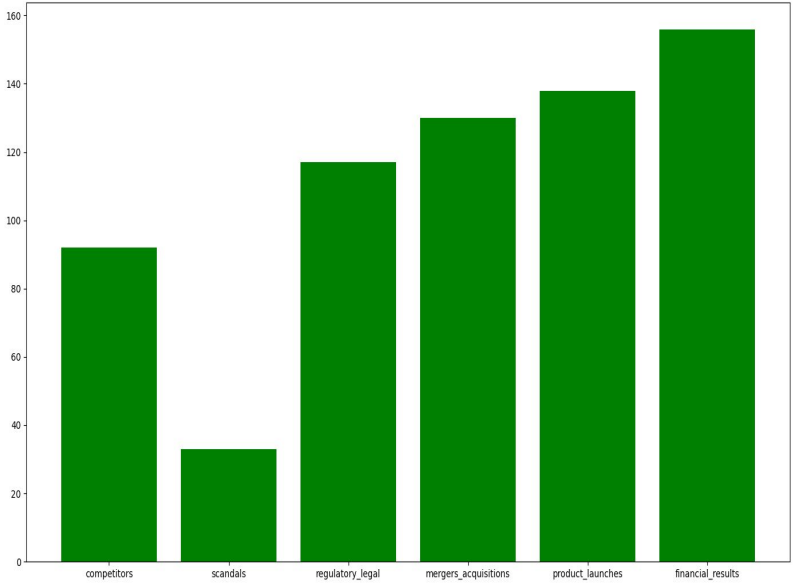

и их распределение во времени

Или более наглядно ->

Распределение плотности

по всем доступным данным:

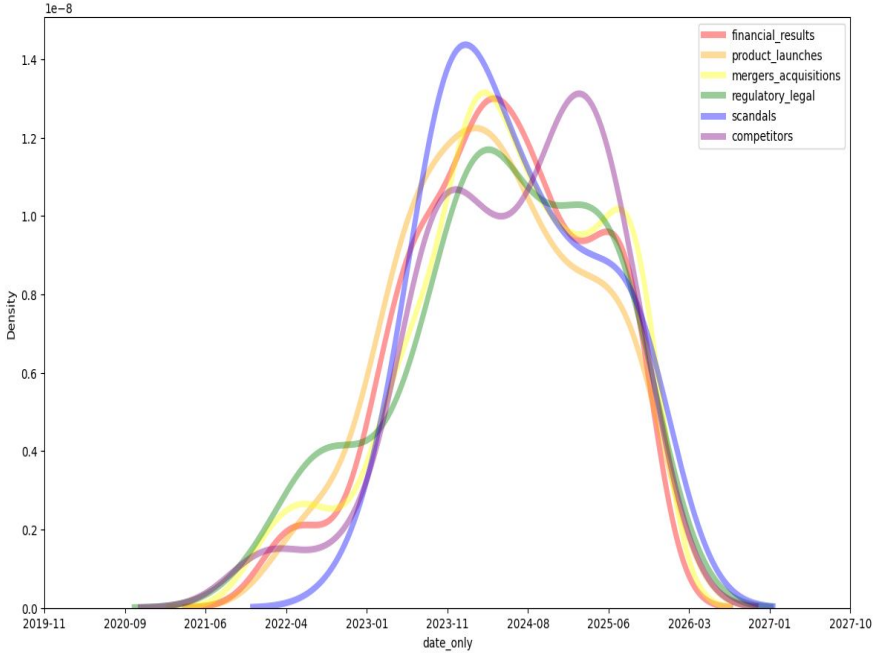

с начала 2022:

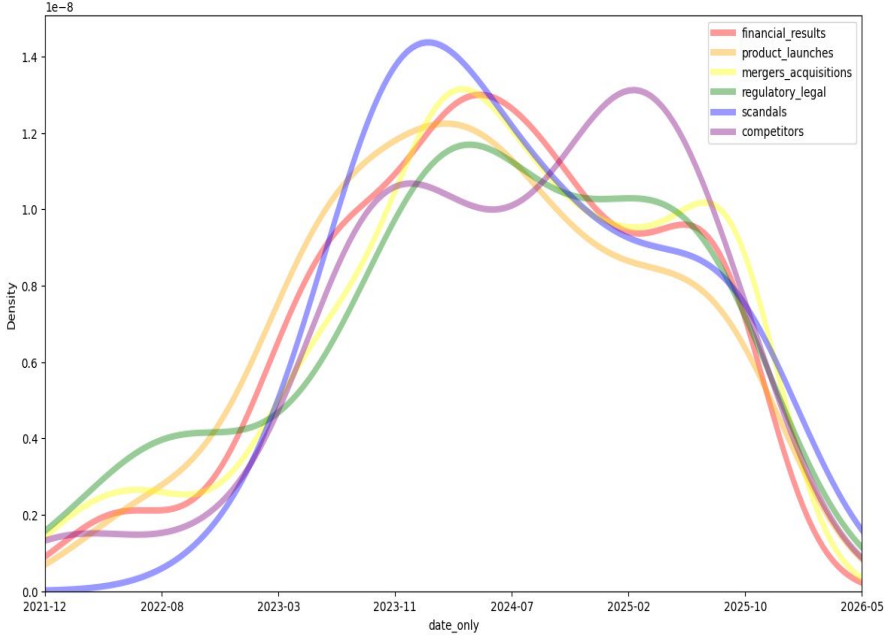

EDA по данным Nvidia

Средние изменение цены по категориям показыавет, на сколько и в какую сторону двигается рынок из-за определённых категорий

Коэффициент влияния показывает отношение доли категории в дни со скачками к доли категории во все дни.

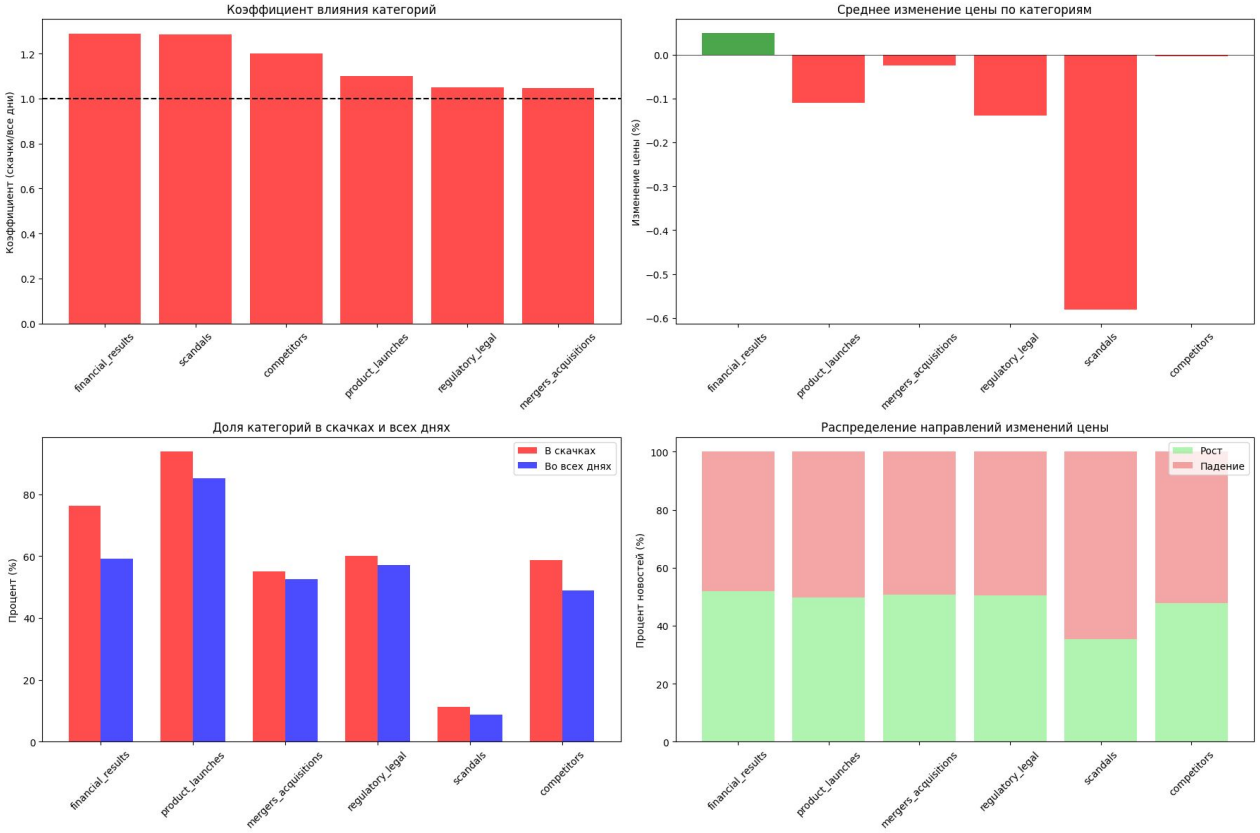

Обзор данных: датасеты для IT-компаний

В датасете с новостями и стоимостью акций 9 признаков:

1. date - дата и время выхода новости
2. title - заголовок новости
3. url - ссылка на новость в формате URL
4. company - название компании, о которой новость
5. type - тип/категория новости
6. open - цена акции определенной компании на момент открытия торгов в определенный день
7. close - цена акции определенной компании на момент закрытия торгов в определенный день
8. volume - объем торгов акцией компании (количество акций; проданных за день)
9. change_pct - суточное изменение цены акции в процентах

Обзор данных: датасеты для IT-компаний

В датасете с макропоказателями 12 признаков:

1. date - дата наблюдения (торговый день)
2. xau_usd_oz - цена золота в долларах США за тройскую унцию
3. xag_usd_oz - цена серебра в долларах США за тройскую унцию
4. wti_usd_bbl - цена нефти WTI (West Texas Intermediate) в долларах США за баррель
5. brent_usd_bbl - цена нефти Brent в долларах США за баррель
6. fedfunds_daily_pct - процентная ставка по федеральным фондам США (ежедневное значение в %)
7. nasdaq_close - закрытие индекса Nasdaq
8. btc_usd - курс биткоина к доллару США
9. open - цена акции определенной компании на момент открытия торгов в определенный день
10. close - цена акции определенной компании на момент закрытия торгов в определенный день
11. volume - объем торгов акцией компании (количество акций; проданных за день)
12. change_pct - суточное изменение цены акции в процентах

Meta: макропоказатели

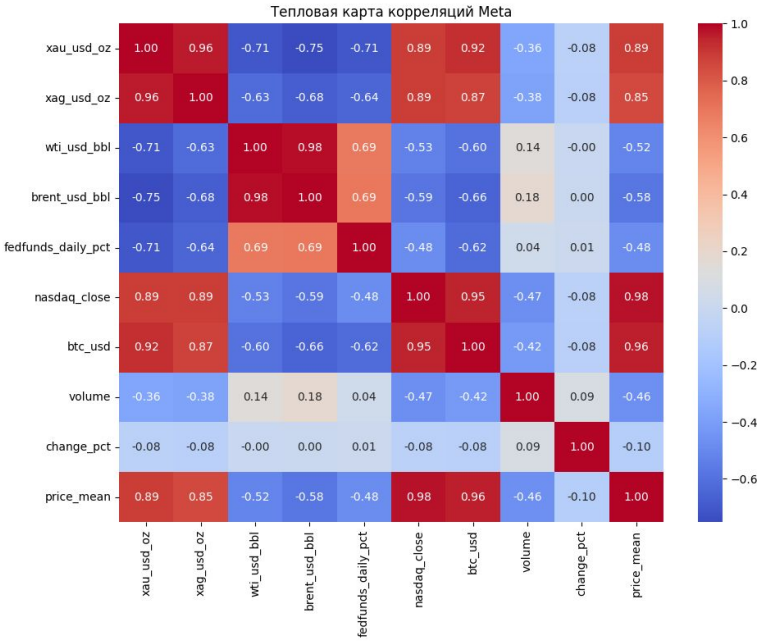

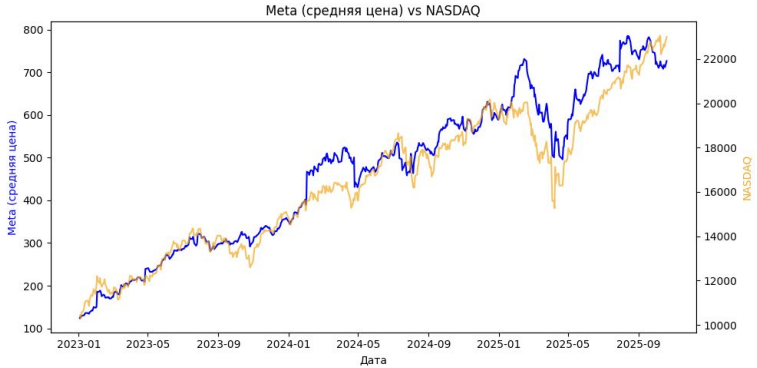

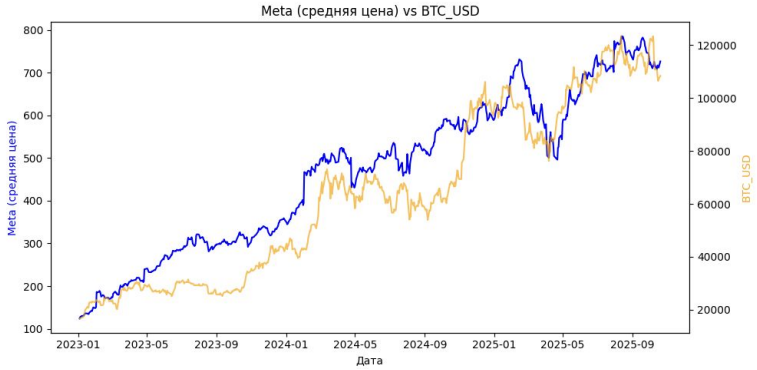

Акции Meta демонстрируют сильную положительную связь с динамикой индекса **NASDAQ** и курса **BTC**, что отражает зависимость компании от общего настроения на технологическом рынке. Рост фондового и крипторынков сопровождается ростом цен на акции Meta.

Oracle: макропоказатели

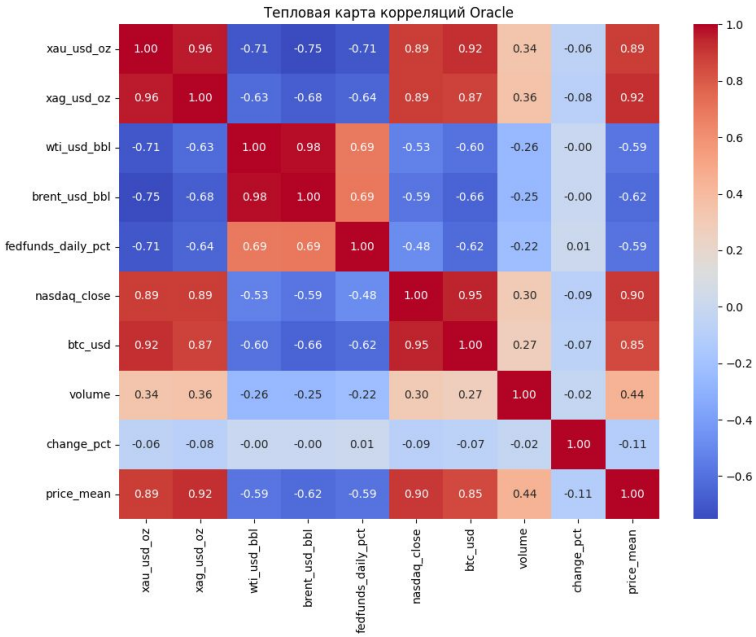

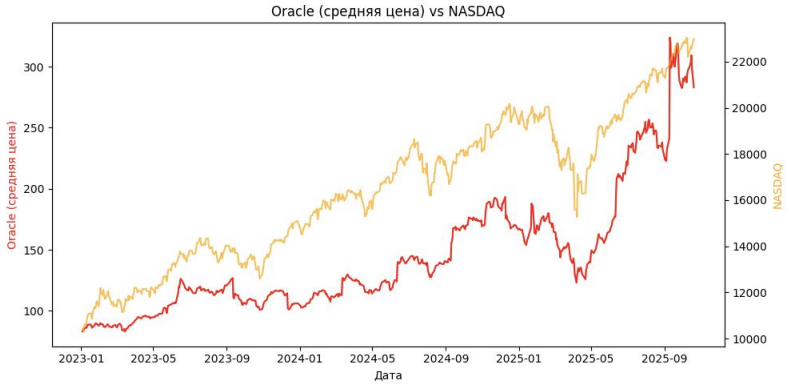

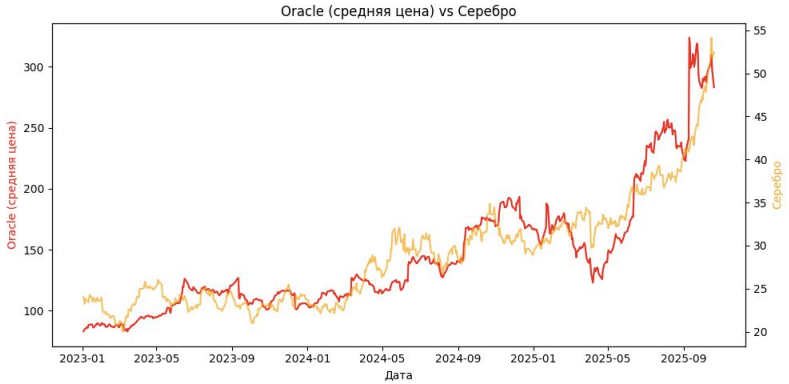

Акции Oracle демонстрируют тесную связь с динамикой **NASDAQ**, отражая общие тенденции технологического сектора. Также наблюдается положительная зависимость от стоимости **серебра**, что может указывать на чувствительность компании к колебаниям товарных и инвестиционных рынков.

Palantir: макропоказатели

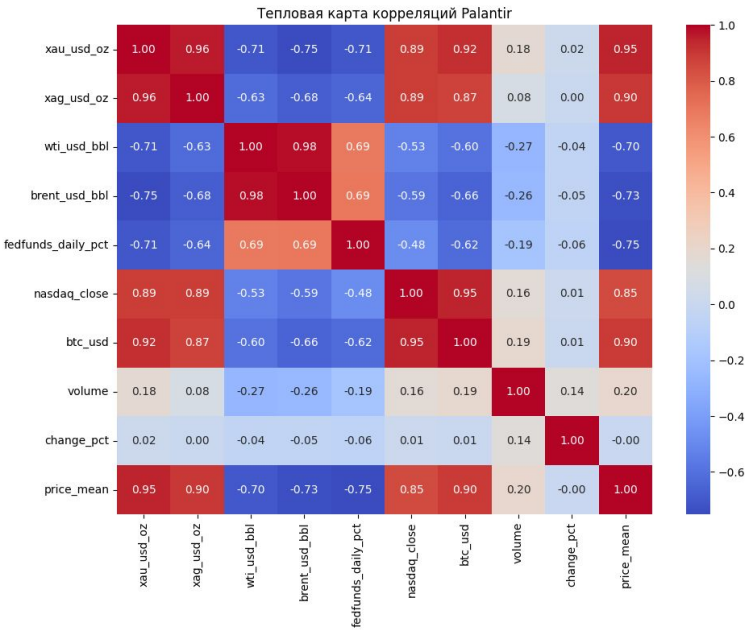

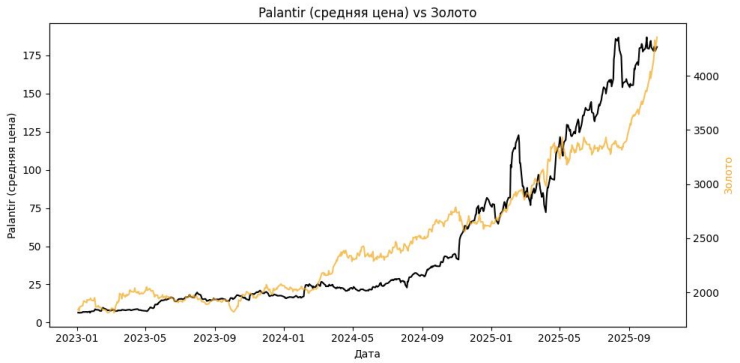

Акции Palantir показывают сильную положительную связь с ценой **золота** и курсом **биткоина**, что, опять же, отражает зависимость компании от общего инвестиционного настроя и технологических активов.

Microsoft: макропоказатели

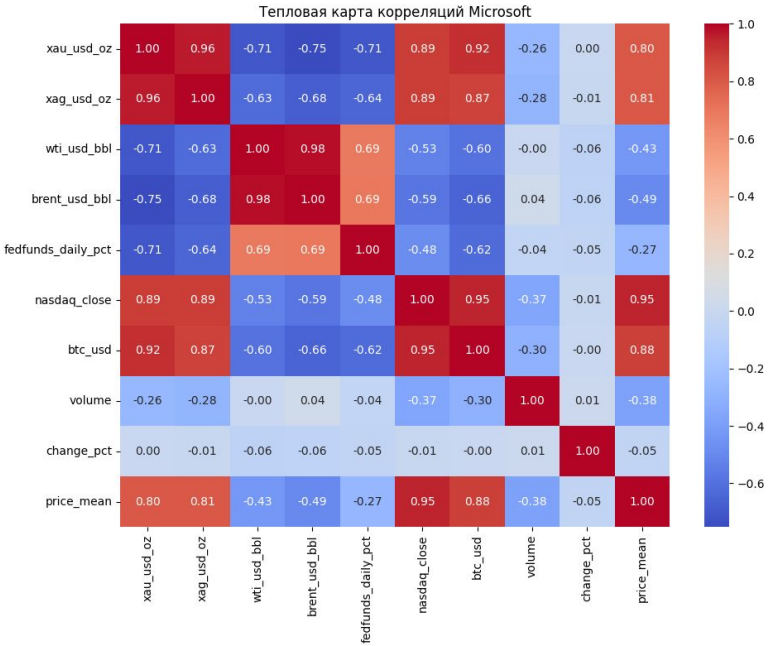

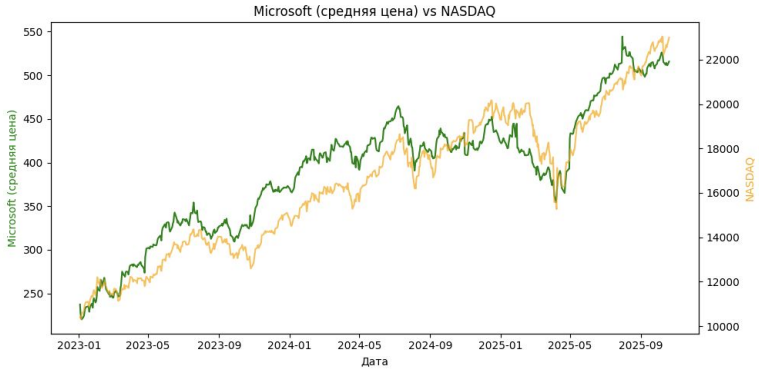

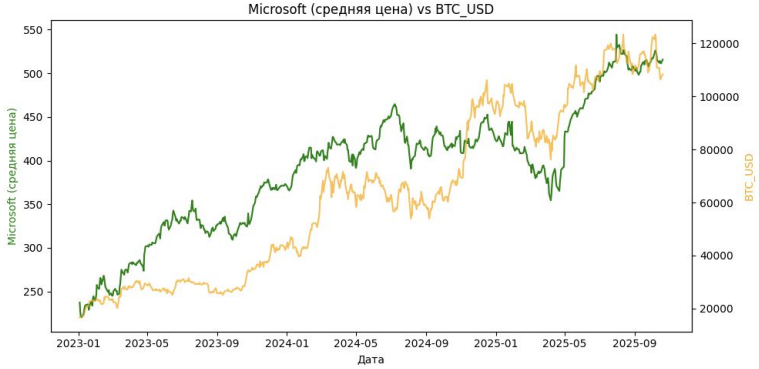

Цены на акции Microsoft демонстрируют устойчивую положительную корреляцию с индексом **NASDAQ** и курсом **BTC/USD**, подтверждая тесную зависимость компании от общей динамики технологического сектора и интереса инвесторов к цифровым активам.

Google: макропоказатели

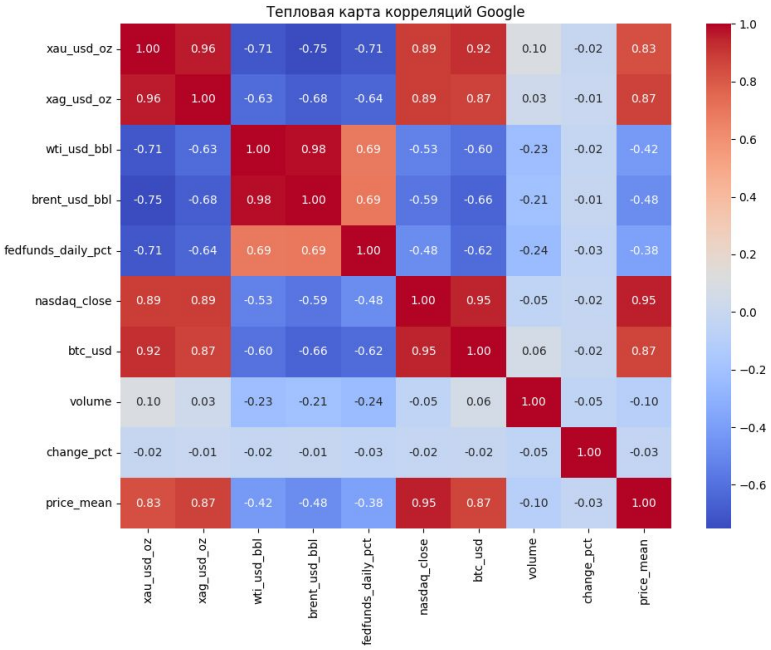

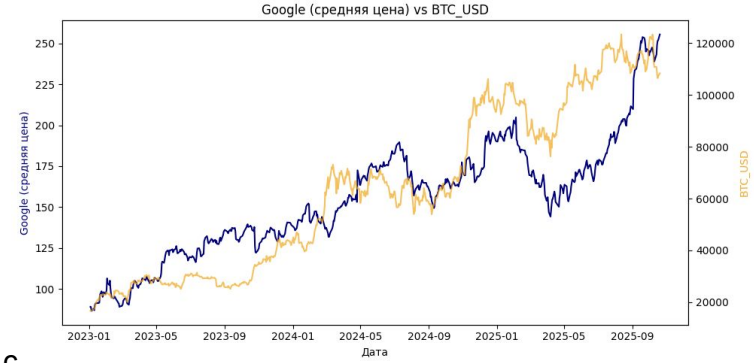

Динамика акций Google тесно связана с индексом **NASDAQ** и частично с курсом **биткоина**, что указывает на зависимость компании от тенденций технологического сектора и общего инвестиционного интереса к IT-рынку

Категории новостей

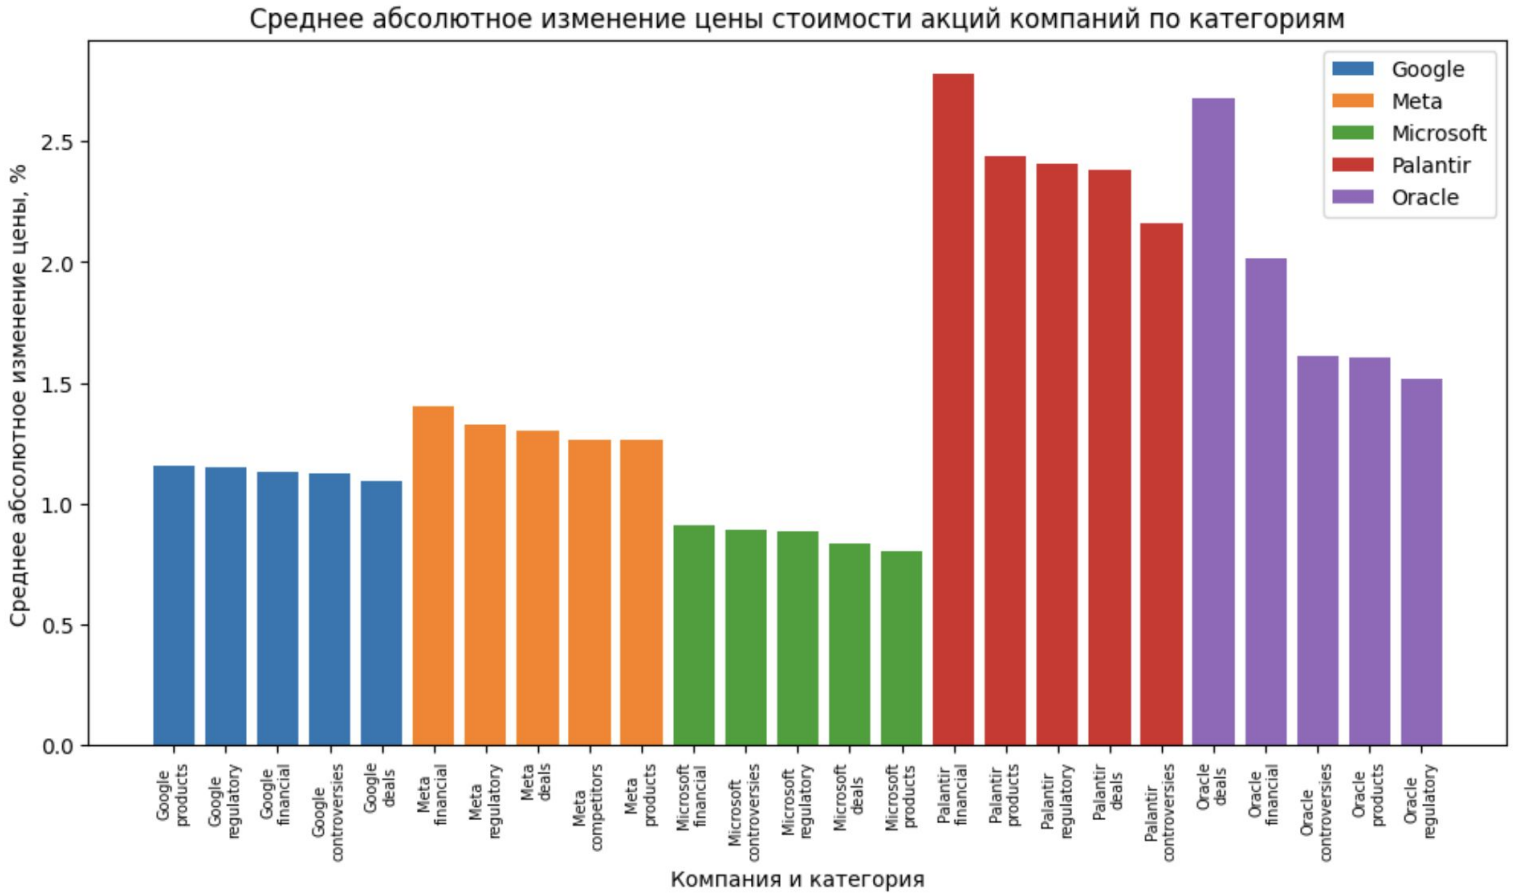

Категории новостей: Meta

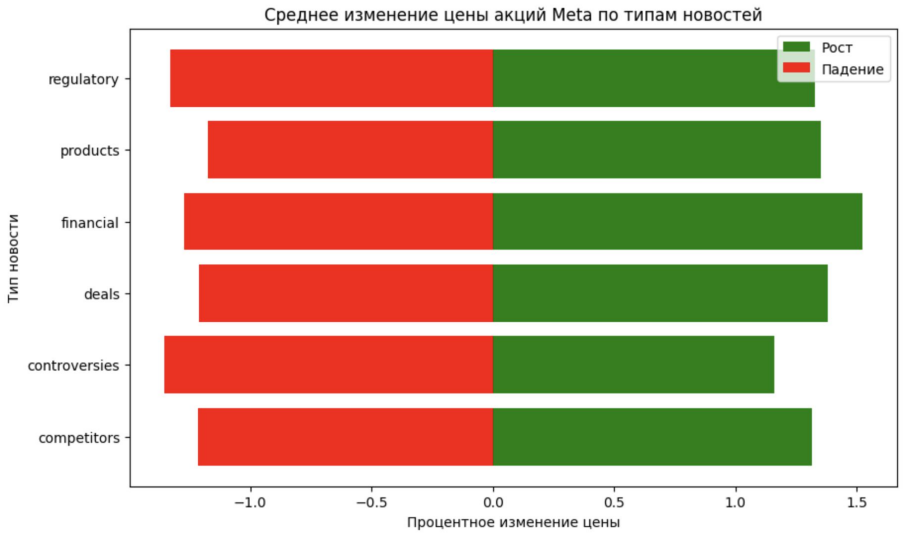

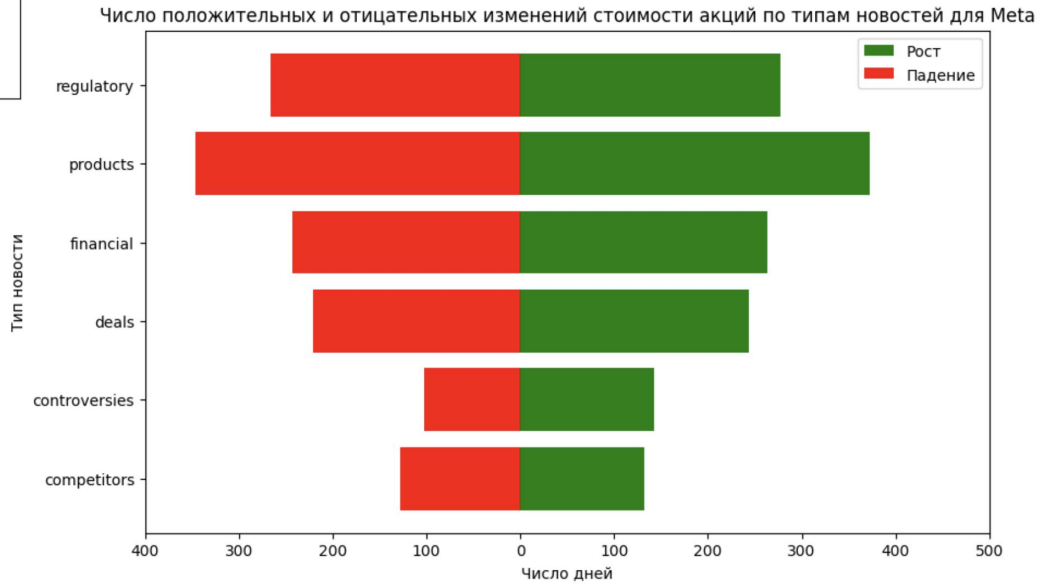

Новости о **новых продуктах** и **сделках** чаще сопровождаются ростом акций Meta тогда как **регуляторные** и **скандальные** новости приводят к снижению. Наибольшее влияние оказывают события, связанные с продуктами компании.

Категории новостей: Oracle

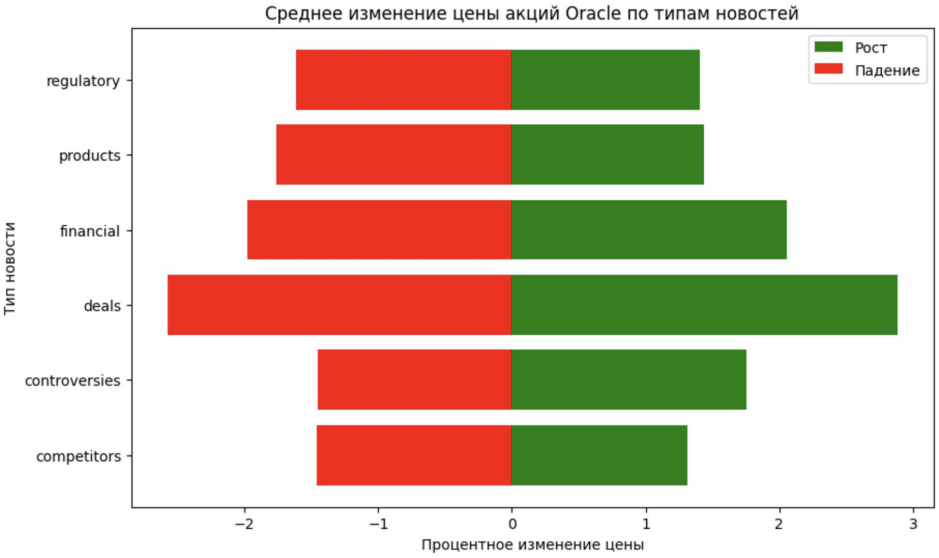

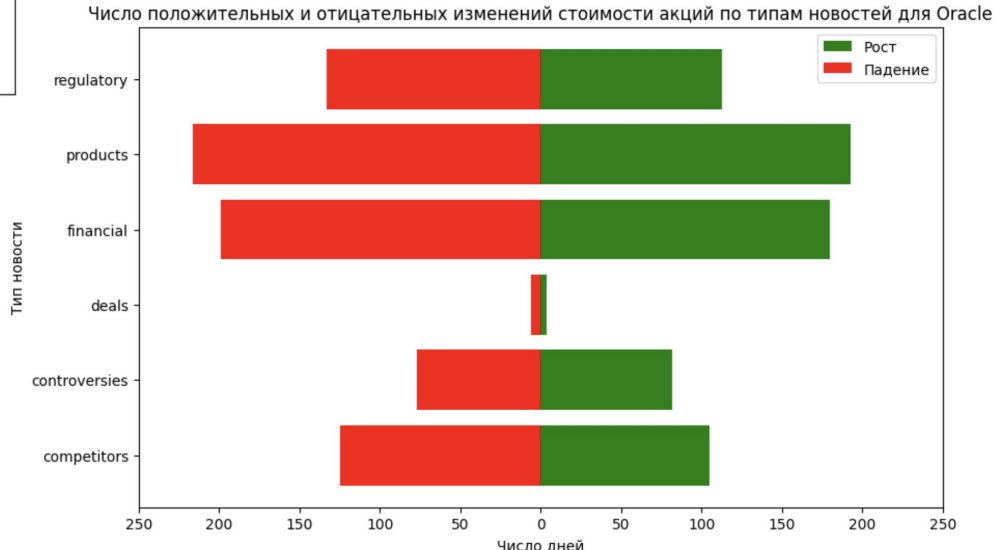

Акции Oracle сильнее реагируют на **финансовые** и **продуктовые** новости — такие события чаще ведут к росту. Напротив, **регуляторные ограничения** и **скандалы** заметно снижают цену акций.

Категории новостей: Palantir

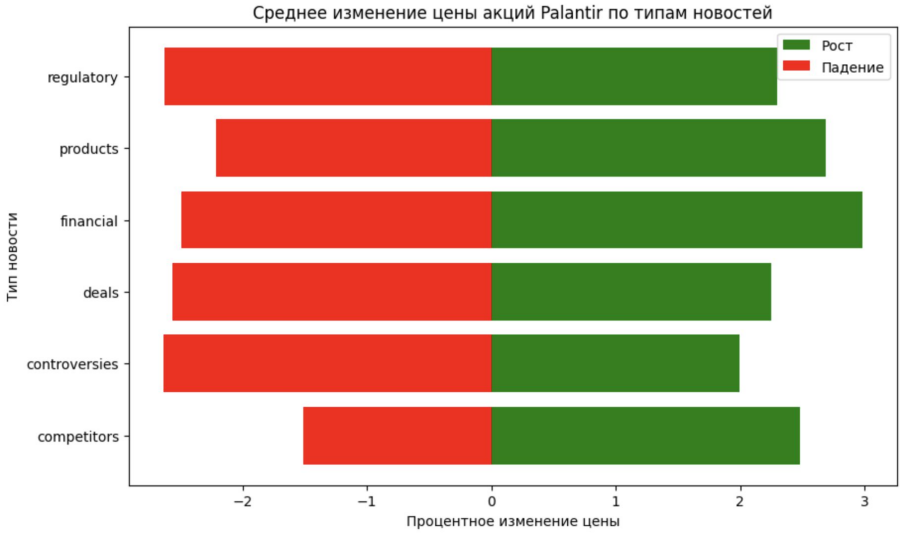

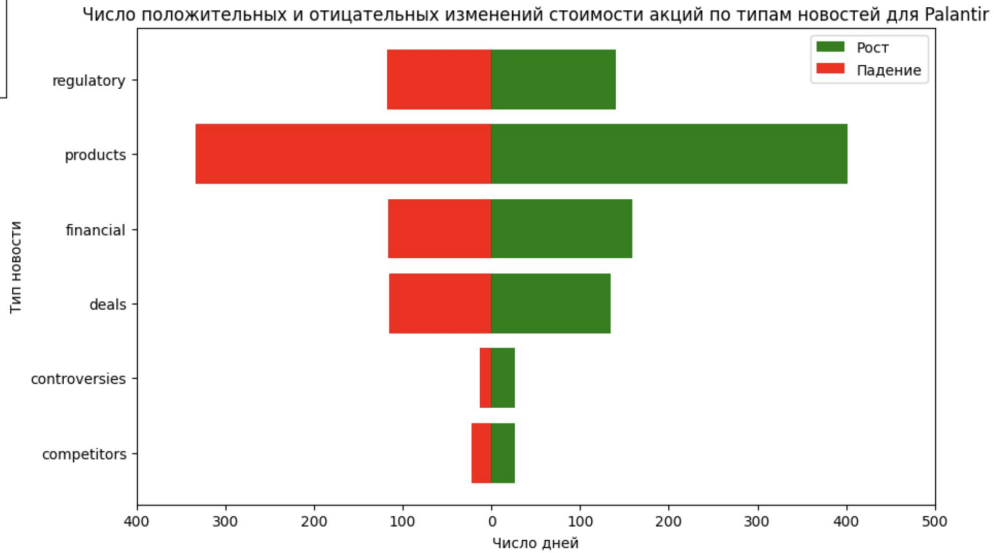

Для Palantir наибольший положительный эффект дают **новости о продуктах** и **финансовые отчеты**, тогда как **регуляторные** и **скандальные** события вызывают падение котировок.

Категории новостей: Microsoft

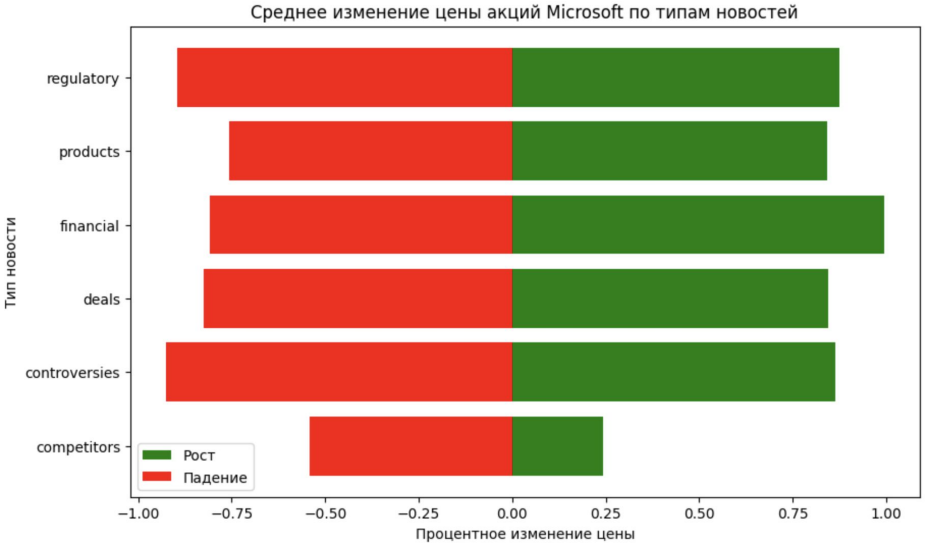

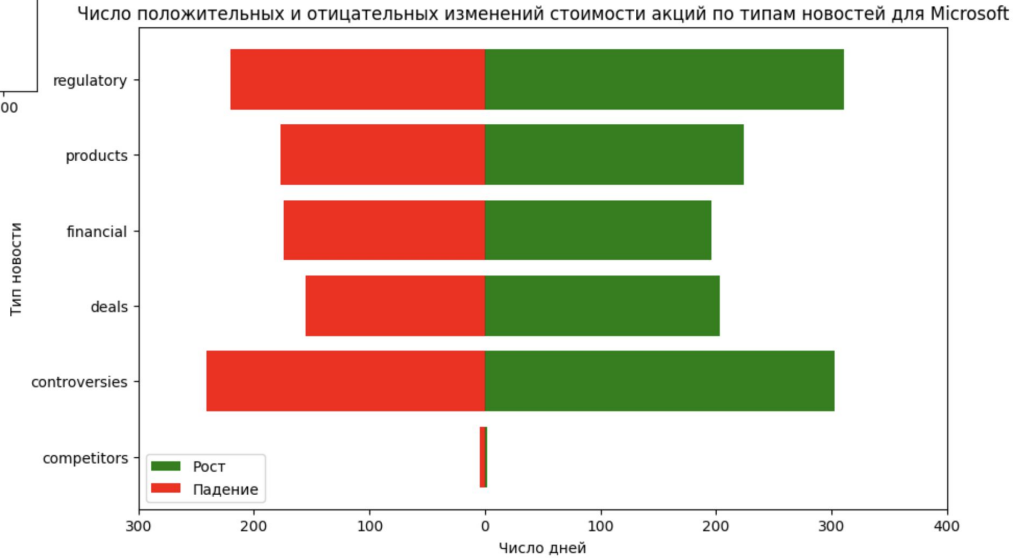

Акции Microsoft растут на **новостях о продуктах** и **сделках**, подтверждая устойчивость компании и доверие инвесторов, но чувствительны к **регуляторным** сообщениям и **конкурентным рискам**.

Категории новостей: Google

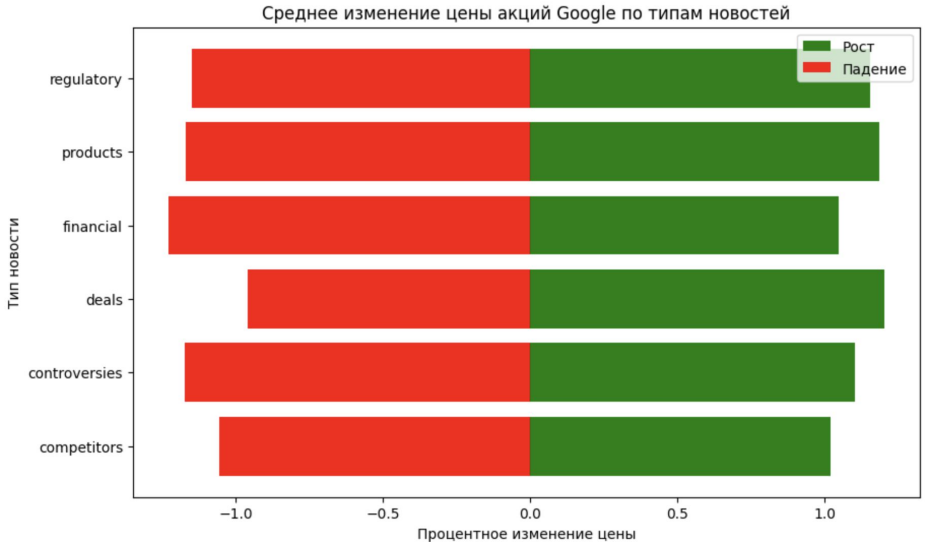

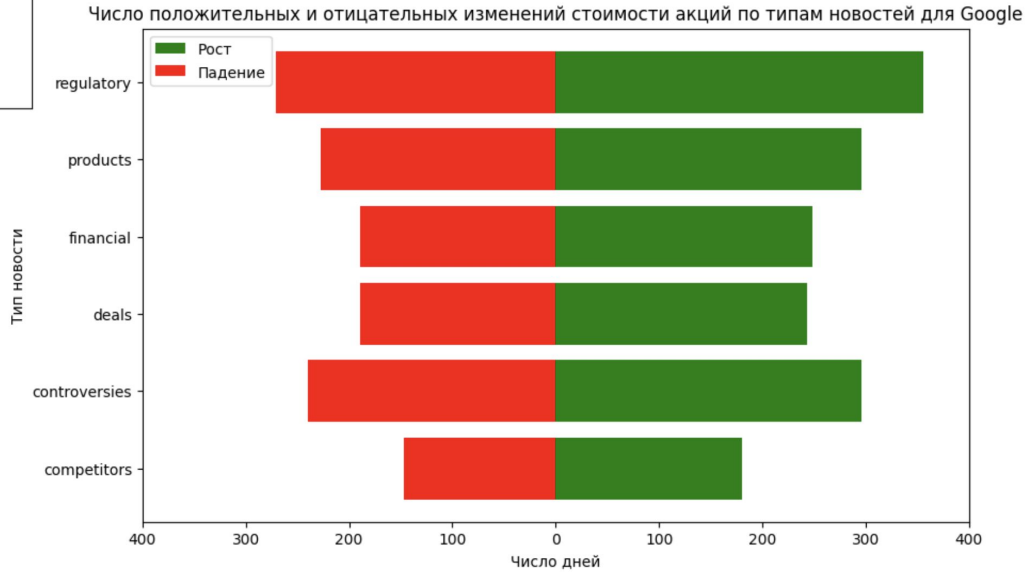

Для Google основным драйвером роста остаются **новости о продуктах** и **регуляторные успехи**, в то время как **финансовые отчеты** и **скандалы** чаще вызывают краткосрочные снижения цены акций.

Бизнес-выводы

1. Наиболее предсказуемая категория для NVIDIA - скандалы, имеет место открытие позиций на понижение при появлении таких новостей.
2. Чаще всего на акции NVIDIA влияет категория финансовых результатов, причем положительно. Выход таких новостей положительно скажется на инвестиционном портфеле.
3. Для всех рассмотренных компаний (*Meta, Google, Microsoft, Oracle, Palantir*) отмечается высокая зависимость котировок от динамики индекса NASDAQ и в меньшей степени от курса BTC/USD. Это подчеркивает общую чувствительность технологического сектора к рыночным настроениям и инвестиционному интересу к IT-активам. Рост фондового и крипторынков сопровождается укреплением позиций технологических компаний.
4. Наибольший положительный эффект на стоимость акций оказывают новости о продуктах, сделках и финансовых результатах, тогда как регуляторные ограничения и скандалы приводят к снижению котировок. Для инвестора это создает возможность оперативного реагирования на новостной поток: усиление позиций при выходе продуктовых и финансовых новостей и хеджирование — при появлении негативного информационного фона.