Групповой проект №3: Statistics

Выполнили:
Азаров Александр ББИ2402

Алышов Виталий ББИ2402

Глодя Мария ББИ2402

Мерцалов Владимир ББИ2402

Морев Егор ББИ2402

Якушина Анна ББИ2402

Постановка задачи.

Part 1 Анализ A/B тестирования.

1. **user_id** - ID человека
2. **timestamp** - временная отметка показа страницы
3. **group** - группа, к которой относится человек: контрольная или тестовая
4. **landing_page** - версия лендинговой страницы, которая была показана
5. **converted** - было ли совершено целевое действие

Задача: проверить, лучше ли новая версия лендинга страницы сайта влияет на конверсию пользователей.

Целевая метрика - conversion rate
Рассчитывается для каждой группы отдельно:
(кол-во converted = 1)/количество наблюдений

EDA

Part 1 Анализ A/B тестирования.

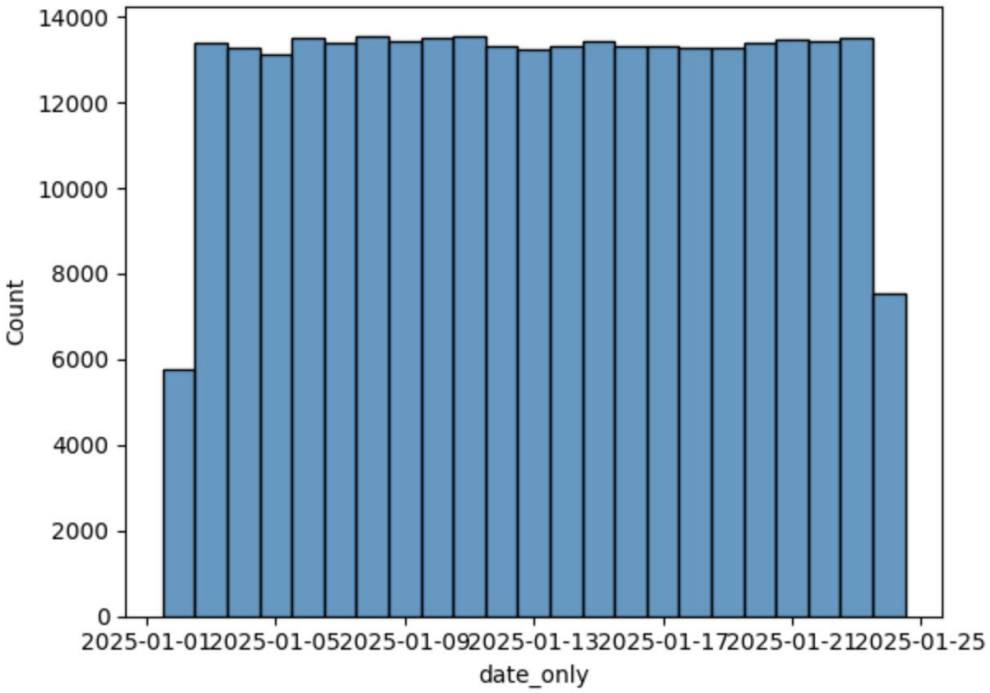

EDA

Part 1 Анализ A/B тестирования.

group	landing_page	
control	old_page	145274
	new_page	1928
treatment	new_page	145311
	old_page	1965

В ходе анализа обнаружились пользователи из тестовой выборки со старым лендингом и пользователи из контрольной выборки с новым лендингом.

Мы провели анализ времени итераций и пришли к выводу, что это не A/A тест, а ошибка распределения.

После устранения ошибочных данных, в датасете остался только один дубликат, который также является ошибкой

EDA

Part 1 Анализ A/B тестирования.

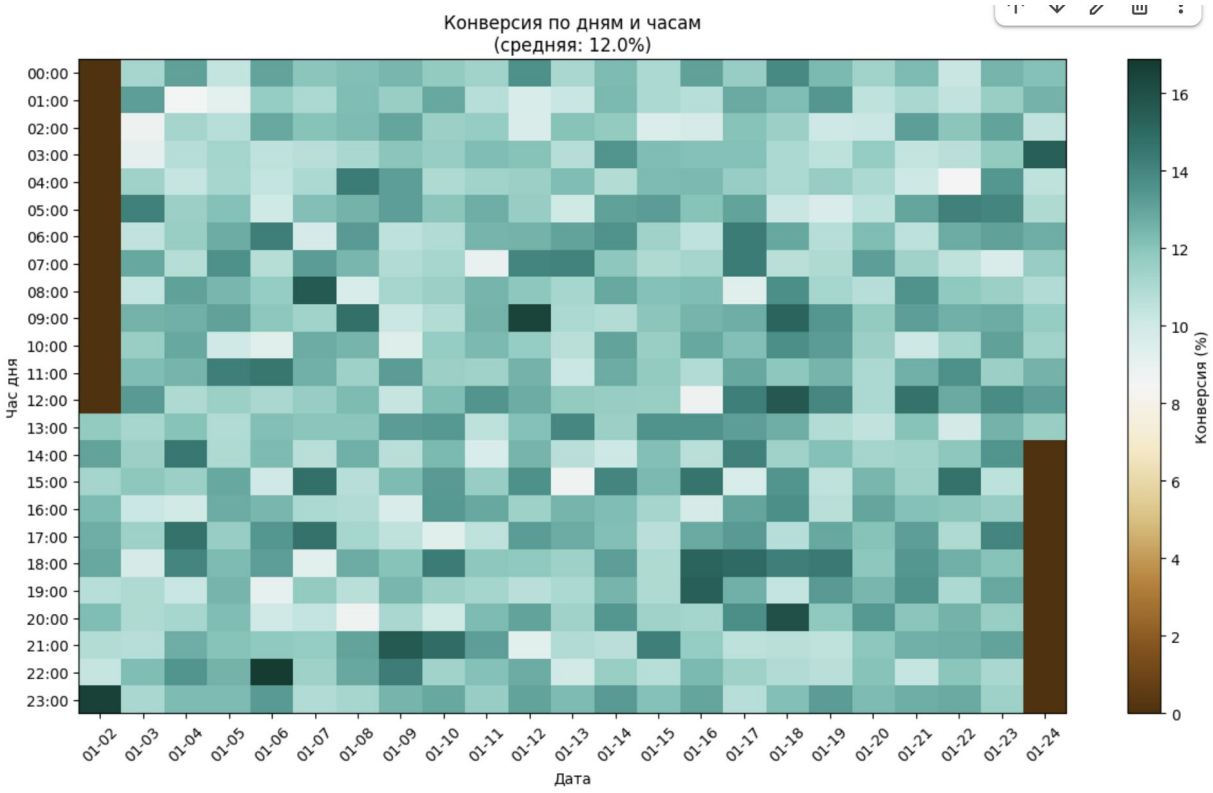

EDA

Part 1 Анализ A/B тестирования.

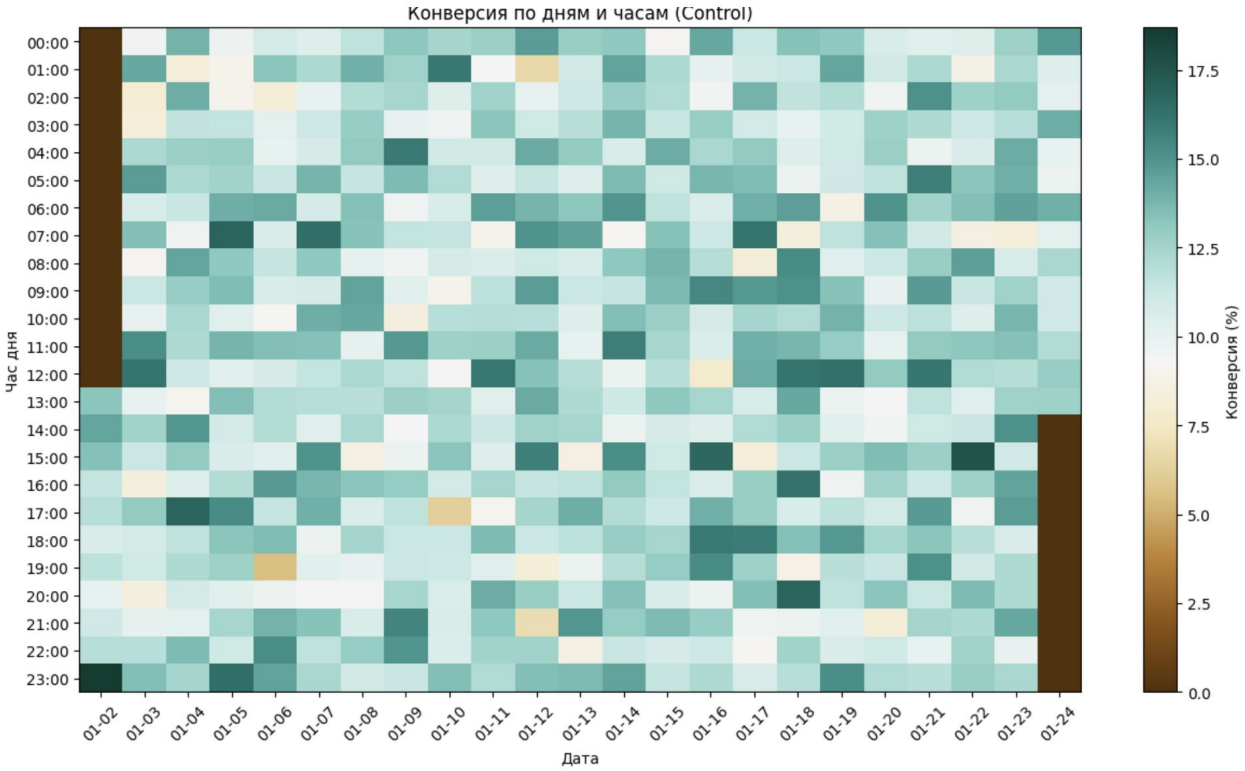

EDA

Part 1 Анализ A/B тестирования.

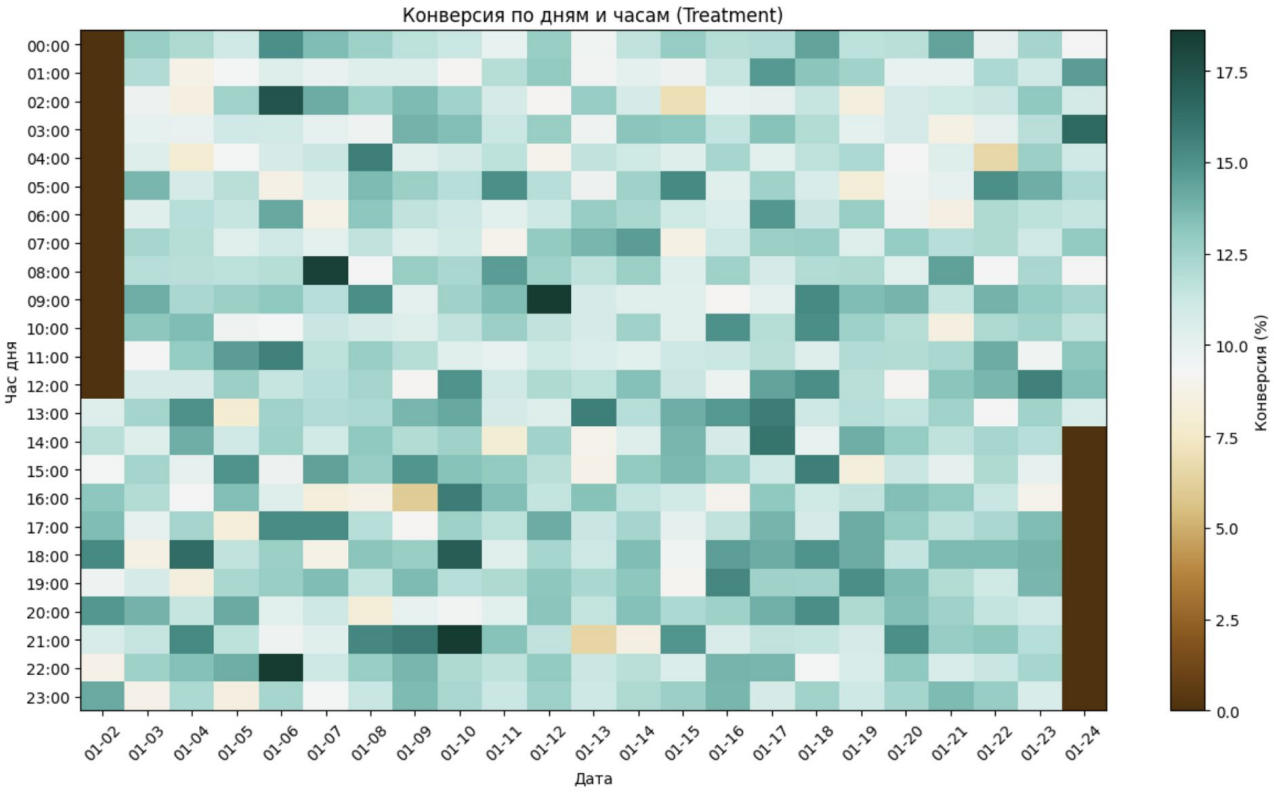

Распределение уровней конверсий. Part 1

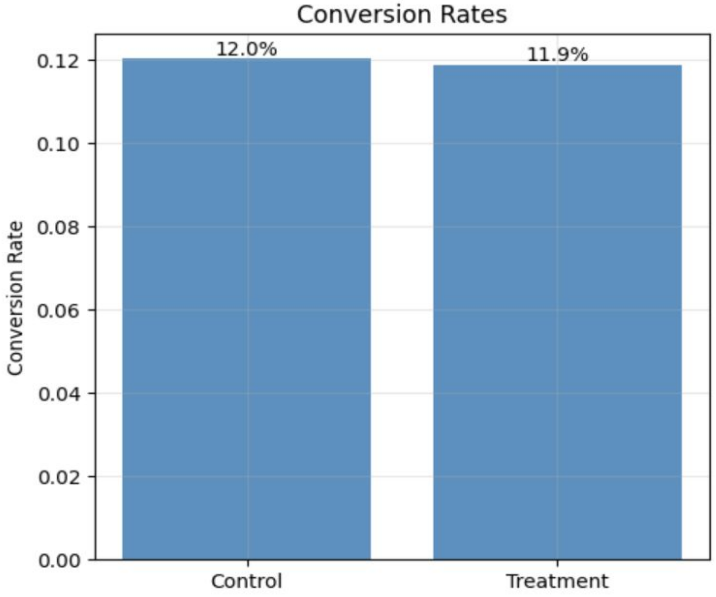

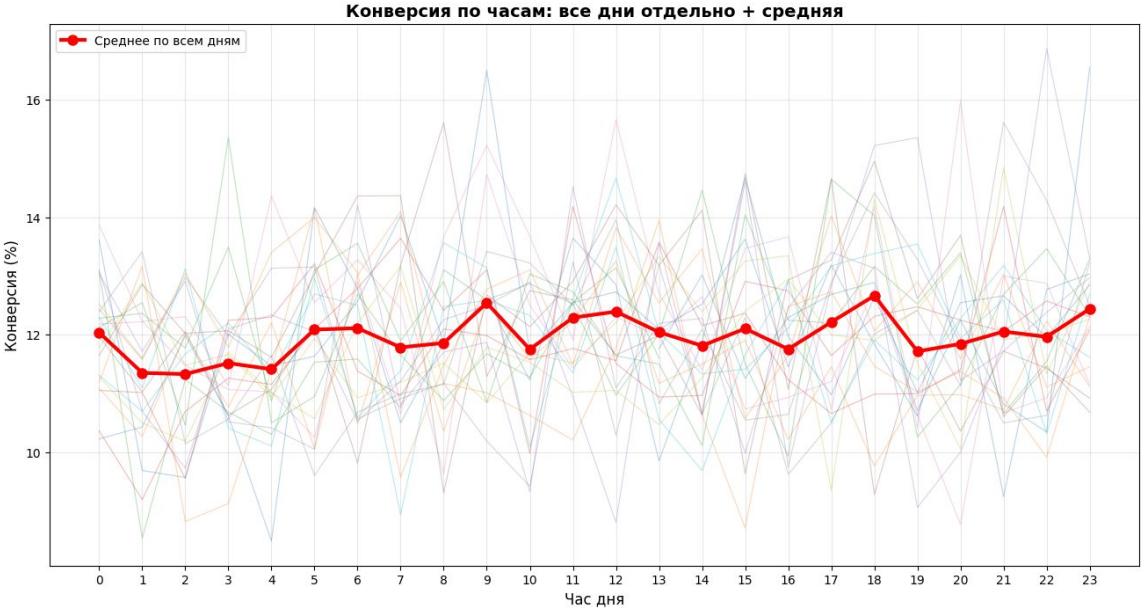

Part 1

Объективность A/B теста и анализ чувствительности к временной составляющей эксперимента.

H0: Распределения по часам групп Control и Treatment не различаются

H1: Распределения по часам групп Control и Treatment статистически значимо различаются.

Инструменты: ~~Хи-квадрат тест~~ , Тест Колмогорова-Смирнова, оценка RMSE.

Проверка и статистическая оценка A/B теста различными методами.

Part 1

H0: новый тип лэндинга не лучше старого.
H1: новый тип лэндинга лучше старого.
Если нам не удастся отвергнуть нулевую гипотезу при заданном уровне значимости 5%, у нас не будет статистических оснований считать, что новый лэндинг лучше. Бизнес-решение об изменениях в этом случае должно приниматься с осторожностью, учитывая стоимость внедрения и потенциальные риски.

Выбор уровня значимости в 5% обусловлен прецедентом использования: зачастую в бизнесе берётся именно такое значение. Выборка достаточно большая, что говорит о масштабности компании, для которой проводилось A/B тестирование, следовательно цена ошибки 1-го рода более существенной для бизнеса (получение ложноположительных результатов в пользу новой страницы, когда на самом деле она "хуже" старой) будет существенна(можем потерять клиентов + мы не знаем каковы затраты на доработку новой страницы), но не катастрофична.

Проверка и статистическая оценка A/B теста различными методами.

Part 1

Предположили, что различий между выборками нет, установили равный уровень конверсии по исходным данным. Сгенерировали множество экспериментов (метод Монте-Карло).
Посмотрим на разницу в конверсиях групп в смоделированном эксперименте и в реальности.
Оказалось, что в 90% случаев при равных уровнях конверсий их разница больше, чем разница конверсий в исходных данных - это и есть P-value. Не имеем оснований отклонить H0 - новая страница не лучше старой.

Part 1

Основной вывод: Статистически значимой разницы между конверсией в тестовой и контрольной группах не обнаружено (p-value = 0.905).

Тестовая группа не показала значимого увеличения конверсии по сравнению с контрольной (z = -1.310), а доверительный интервал (полученный из бутстрэпа) разницы включает ноль, что подтверждает отсутствие эффекта.

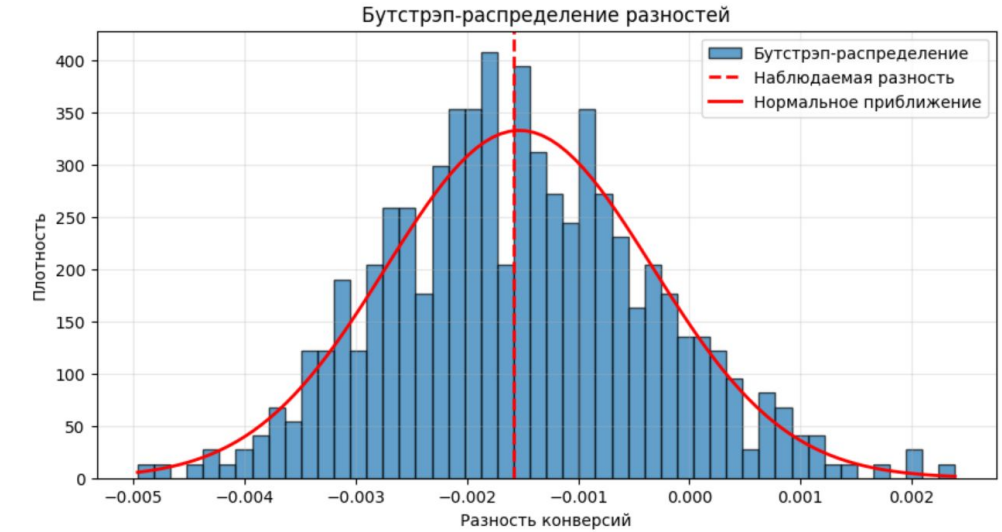

95% бутстрэп-доверительный интервал: [-0.00373524 0.00089111]

Выбор датасета

Part 2

Датасет: Adult

Предметная область - социоэкономическая (перепись населения США).

Постановка задачи.

Мы рассматриваем данные с точки зрения (инвестиционного) банка.

1) HR-подразделения банка.

2) Отдела инвестиций банка.

3) Отдел по работе с бизнесом.

https://archive.ics.uci.edu/dataset/2/adult

Part 2.1 АМАНЯША

Цель исследования — выявить категории кандидатов, которые статистически демонстрируют более высокую и устойчивую рабочую нагрузку, а также определить, как профессия, уровень образования и демографические характеристики связаны с различиями в рабочей нагрузке для ролей с повышенными требованиями к вовлеченности.

- Показатель hours-per-week используется как **поведенческий индикатор** готовности к высокой рабочей нагрузке.
- Анализ направлен не на поощрение переработок.
- Мы рассматриваем рабочие часы как отражение **стиля работы и готовности брать дополнительную нагрузку**.

EDA: Part 2.1

Определили наиболее релевантные для заказчика сферы работы:

1. ‘Exec-managerial',
2. 'Prof-specialty',
3. 'Sales',
4. 'Adm-clerical',
5. 'Tech-support

Представители релевантных сфер составляют ~53%

Определили наиболее релевантные ступени образования потенциального работника:

1. Doctorate
2. Prof-school
3. Masters
4. Bachelors

Самые распространенные из них - Masters и Bachelors

EDA: Part 2.1

В большинстве категорий преобладают мужчины, исключение - Bachelors - Adm-clerical

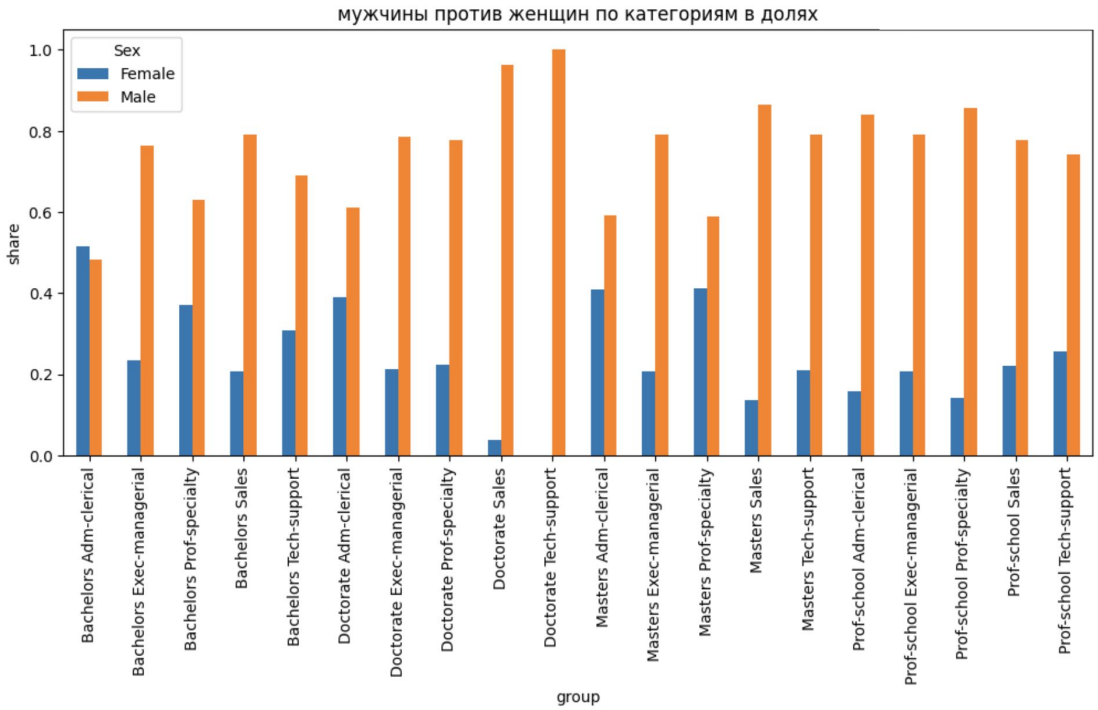

EDA: Part 2.1

Топ-4 категории по демографическим признакам:

- 1я категория: белые женатые мужчины (гражданская супруга)
- 2я категория: белые женщины, никогда не состоявшие в браке
- 3я категория: белые мужчины, никогда не состоявшие в браке
- 4я категория: белые женщины в разводе

Внутри этих категорий выбрали еще и по 2 самых интересующих нас **образования:**

Больше всего во всех 4х категориях нас интересуют уровни образования

- Bachelors
- Masters

Гипотезы:

Part 2.1

1. В рамках наиболее массовых и релевантных HR-категорий белые женатые мужчины с высшим образованием (Bachelors/Masters), занятые в Prof-specialty и Exec-managerial, работают статистически значимо больше часов в неделю, чем остальные выделенные демографические категории с тем же уровнем образования и в тех же профессиях.
2. Среди никогда не состоявших в браке сотрудников различия в трудолюбии (hours-per-week) между мужчинами и женщинами статистически значимы и зависят от профессии.
3. Внутри топовых HR-категорий люди, со степенью Masters имеют более высокую трудовую нагрузку (hours-per-week), по сравнению с уровнем Bachelors.
4. Вероятность высокой трудовой нагрузки (работа более 40 часов в неделю) различается между профессиями среди HR-релевантных кандидатов.

Гипотеза 1:

Part 2.1

H0: среднее hours-per-week не выше у белых женатых мужчин с высшим образованием (Bachelors/Masters), занятых в Prof-specialty и Exec-managerial по сравнению другими демографическими категориями

H1: у белых женатых мужчин с высшим образованием(Bachelors/Masters), занятых в Prof-specialty и Exec-managerial среднее hours-per-week выше

Тест: Манна-Уитни

(тк выборки распределены не нормально)

Результаты: pvalue < 0.05

=> нулевую гипотезу

=> среднее hours-per-week НЕ не выше у белых женатых мужчин с высшим образованием (Bachelors/Masters), занятых в Prof-specialty и Exec-managerial по сравнению другими демографическими категориями => есть статистически значимые основания принять **альтернативную** гипотезу

Гипотеза 2:

Part 2.1

H0: внутри профессии распределение hours-per-week одинаково для мужчин и женщин

H1: различия присутствуют хотя бы в одной профессии

Тест: Краскела-Уоллиса

(тк выборки распределены ненормально и их >3)

Результаты: pvalue < 0.05

=> нулевую гипотезу

=> хотя бы в одной профессии могут присутствовать различия по полу

Тесты 2.0: Манна-Уитни, Multipletest

(для попарного сравнения)

Результаты: pvalue < 0.05 для всех релевантных профессий

=> нулевую гипотезу

=> во всех профессиях могут присутствовать различия по полу

Гипотеза 2:

Part 2.1

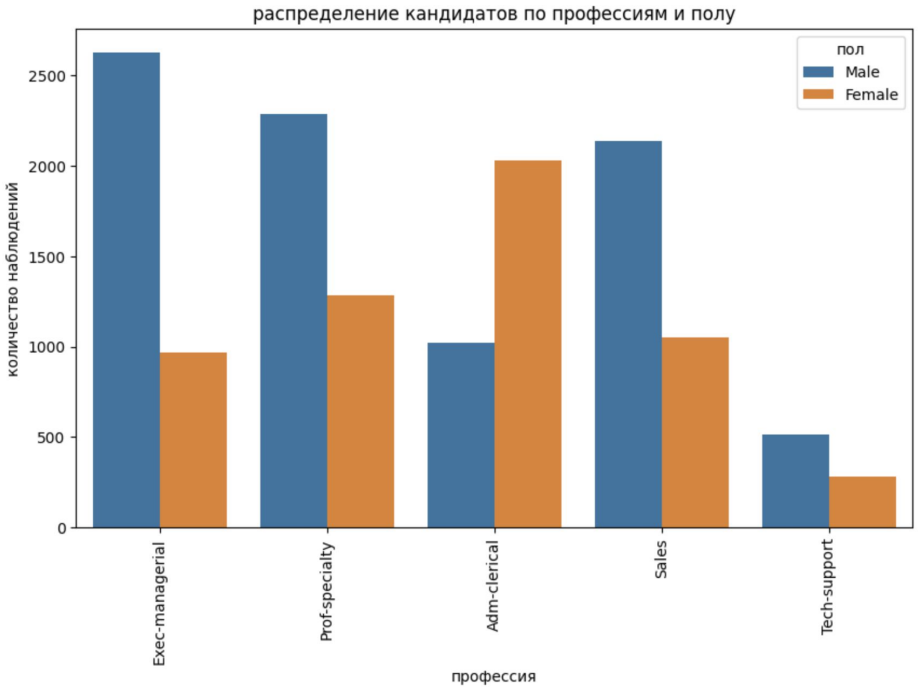

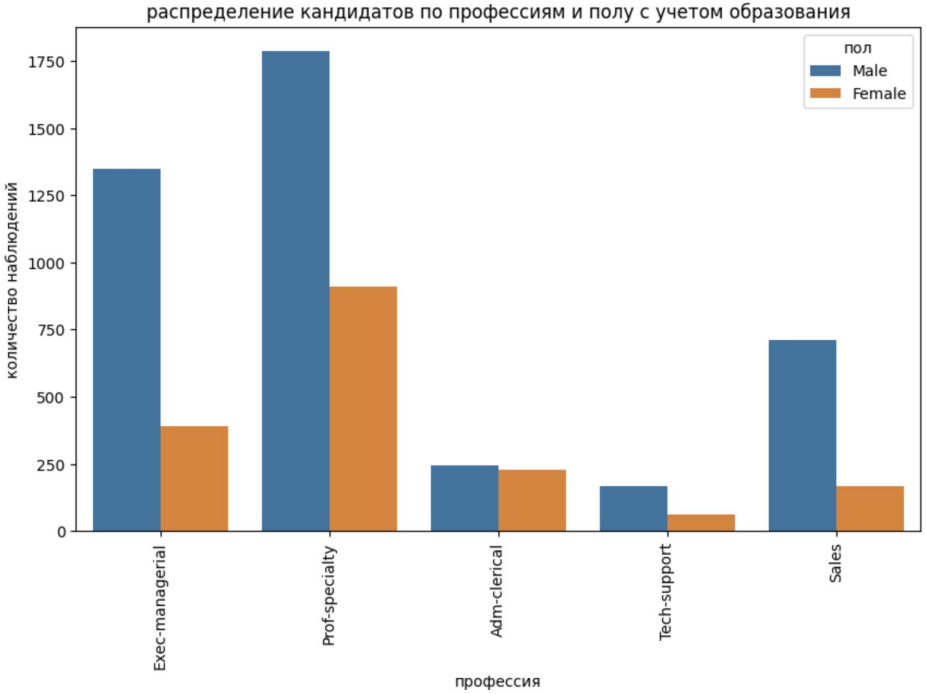

Гипотеза 3:

Part 2.1

H0: средние hours-per-week для Masters не больше, чем для Bachelors

H1: Masters работают больше

Тест: Манна-Уитни

(тк выборки распределены не нормально)

Результаты: pvalue < 0.05

=> нулевую гипотезу

=> Masters работают статистически значимо больше

education	over_40
Bachelors	0.436440
Masters	0.483707

доля людей с соответствующей степенью образования, которые работают больше, чем 40 часов в неделю

Гипотеза 4:

Part 2.1

H0: доля работников с hours-per-week > 40 одинакова для всех профессий

H1: хотя бы для одной профессии доля отличается

Тест: Хи-квадрат

(тк сравниваем доли и рассматриваем категориальные признаки)

Результаты: pvalue < 0.05

=> нулевую гипотезу

=> Вероятность переработки статистически значимо зависит от профессии

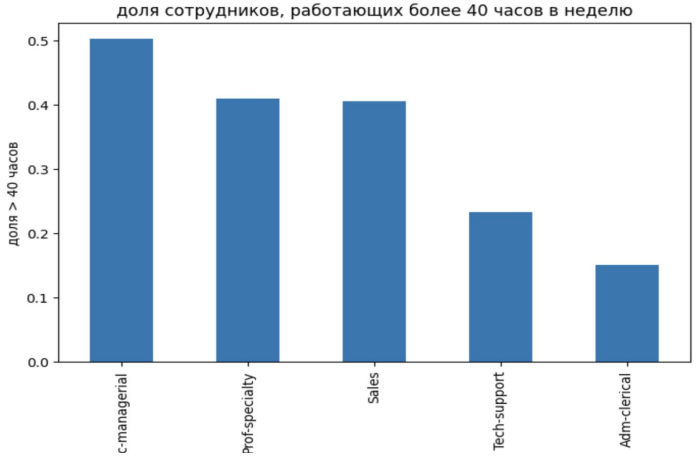

occupation	
Exec-managerial	0.501808
Prof-specialty	0.409129
Sales	0.405388
Tech-support	0.232704
Adm-clerical	0.150820

доля людей, которые работают больше, чем 40 часов в неделю по релевантным профессиям

Бизнес-выводы

Part 2.1

1. Ставшая фаворитом в ходе EDA категория потенциальных работников (White, мужчины, Married-civ-spouse, Bachelors/Masters, Prof-specialty и Exec-managerial) действительно демонстрируют **более высокую трудовую нагрузку**, чем остальные демографические группы, то есть анализ был проведен корректно и эту категорию можно рассматривать как целевую для HR.

2. Внутри одной и той же демографической группы направление гендерных различий в трудовой нагрузке **зависит от профессии**: в Adm-clerical лидируют женщины (на не слишком высоком уровне образования), в то время как в остальных релевантных сферах лидируют мужчины. Универсальные HR-ожидания по полу некорректны и ведут к ошибкам найма

3. При прочих равных кандидаты с Masters представляют собой **более устойчивый выбор** для ролей с высокой вовлеченностью.

4. Вероятность большего числа часов работы **статистически значимо различается между профессиями**, даже внутри одной демографической группы

Цель исследования — изучение столбца Capital_gain и извлечение наиболее ценной информации.

Part 2.2 Саша Вова

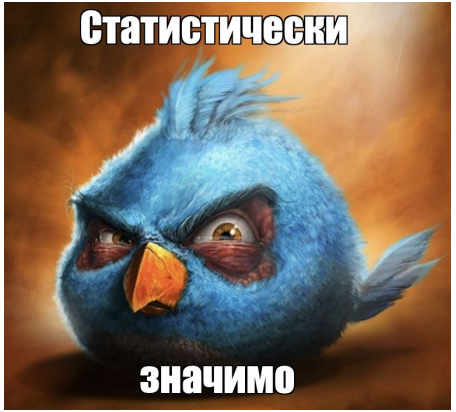

EDA и особенность capital gain

Part 2.2

После чистки дф и feature-инжиниринга мы решили исследовать распределения capital_gain_group по age, sex и education.

Распределение gain по age

Part 2.2

H0: Средний возраст одинаков во всех группах
H1: Средний возраст отличается хотя бы в одной паре

1. проверим нормальность, гомогенность и размеры выборок
2. Шапиро Уилк, тест Левина
3. Используем тест Анова Уэлча
4. Отвергли Но
5. Т-тесты Уэлча

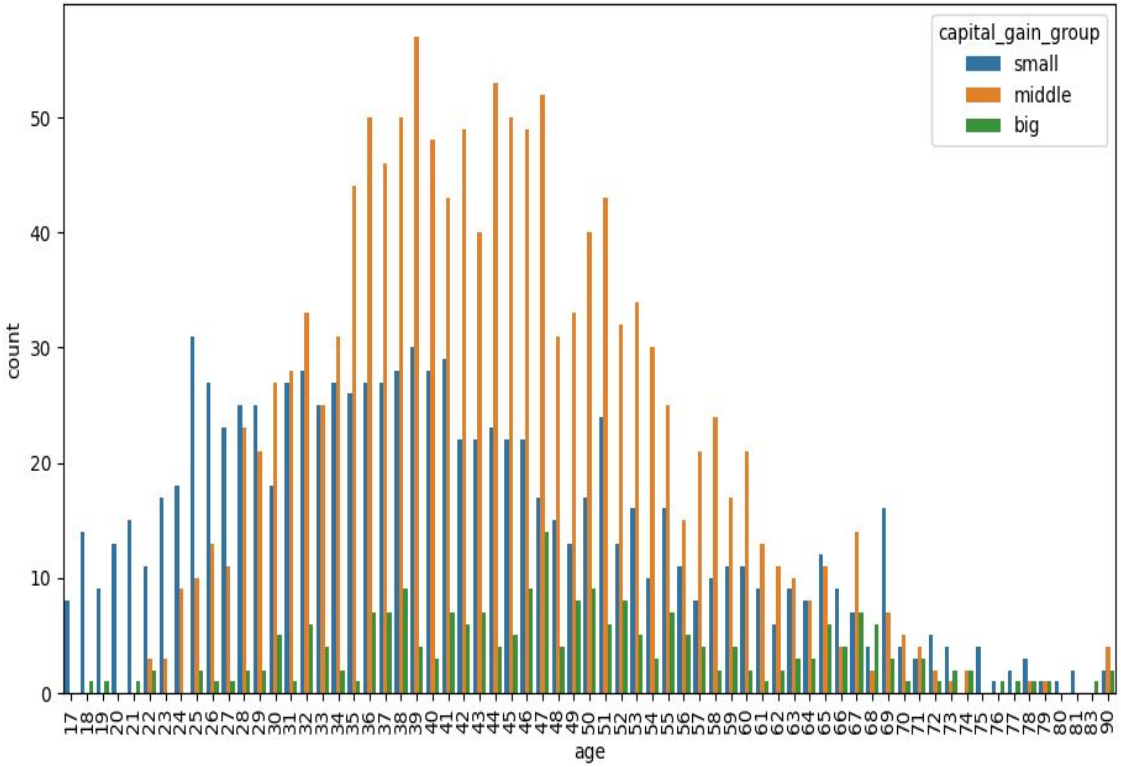

Бизнес выводы

1. Возрастная группа 35–55 лет является ключевой с точки зрения платёжеспособности и должна рассматриваться как приоритетная для продвижения высокомаржинальных продуктов.
2. В возрастной группе 25–35 лет наблюдается переход клиентов из категории small в middle
3. Для возрастных категорий до 25 лет и старше 60 лет характерно доминирование группы small и низкая доля клиентов с высоким приростом капитала.

Распределение по половому признаку.

Part 2.2

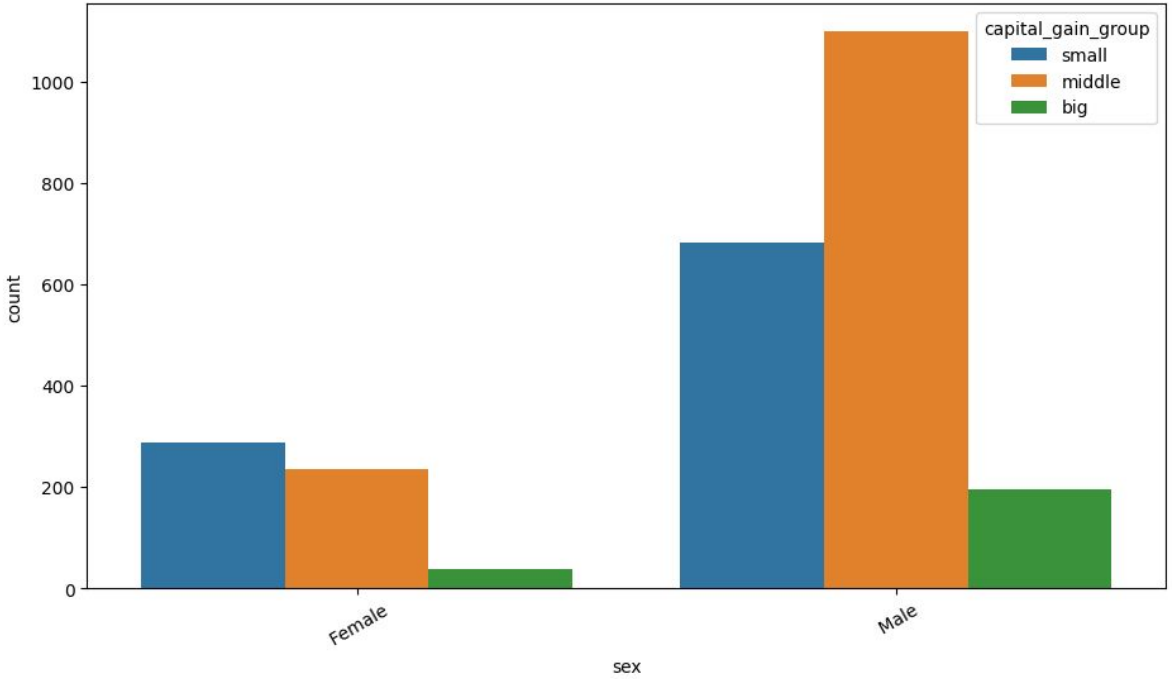

Оцениваем распределение по группам. Part 2.2

H0: Доля мужчин одинакова во всех группах инвесторов.

H1: Доля мужчин различается хотя бы в одной паре групп.

Проверяем гипотезу при помощи Хи квадрат теста. Обоснование: хотим оценить схожесть распределения в выборках.

Результат: уверенно отклоняем нулевую гипотезу.

```
X² = 41.24
p-value = 1.1065640813991892e-09
Степени свободы = 2
```

Распределение по половому признаку

Part 2.2

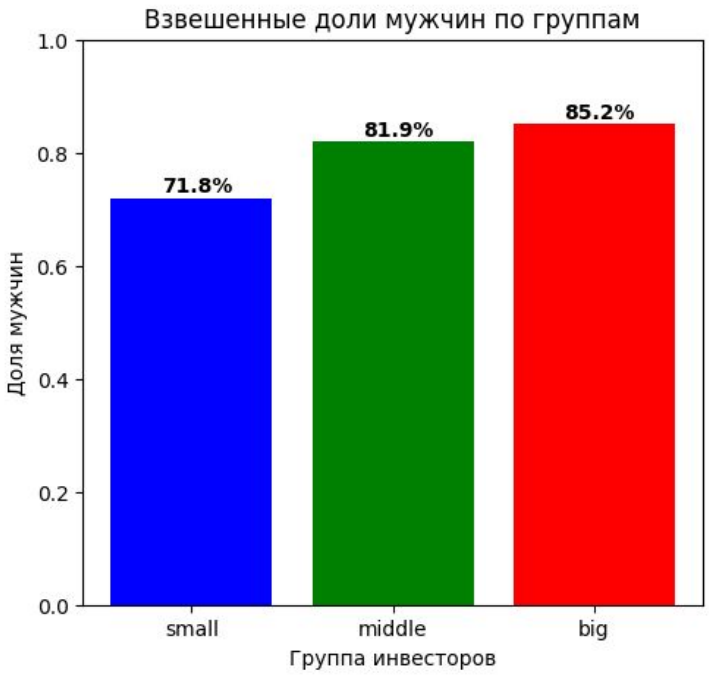

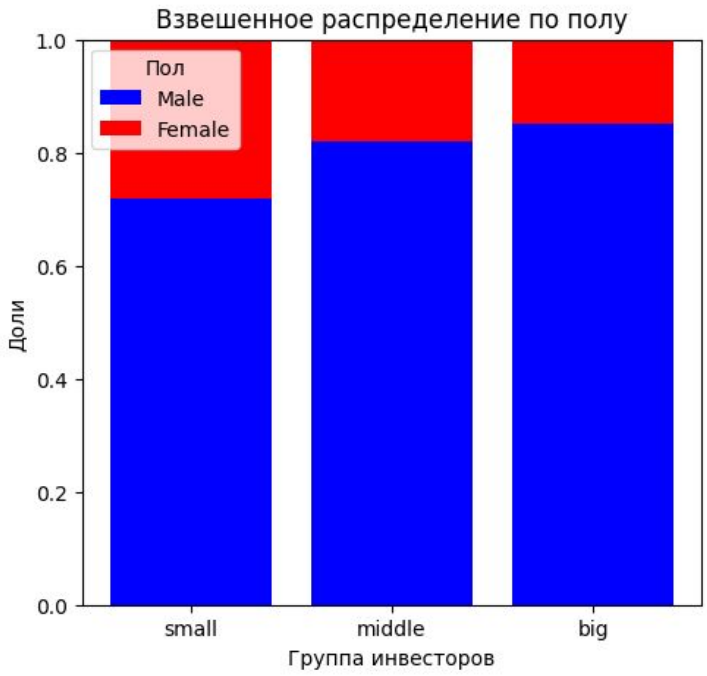

Сравниваем Middle vs BIG

Part 2.2

После оценки распределения повышаем глубину анализа. Если разница между категориями small и middle, big очевидна, то между middle и big - нет. Стоит применить z тест для пропорций, для оценки гипотезы:

H0: Нет различий между категориями Middle и Big.

H1: Есть значимые различия между категориями Middle и Big.

В результате применения Bootstrap’a и Z теста уверенно отклоняем нулевую гипотезу с p_value приблизительно равном нулю.

Бизнес-выводы. Part 2.2

Бизнес выводы: По результатам аналитики предлагаем пул из нескольких различных стратегий.

1) Расширение целевой аудитории. Как можно заметить процент женщин переходящих из категории small в категорию middle сильно падает, следует собрать фокус-группу или провести опрос, чтобы выяснить реальные причины, почему женщины не инвестируют большие суммы.

2) Акцент на текущих клиентах. Чем выше уровень инвестиций, тем выше доля мужчин в таких группах. В таком случае имеет смысл вводить инновации с учётом этой особенности.
Конкретные действия:

- продвигать агрессивные, нацеленные на высокий доход стратегии инвестирования для BIG
- продвигать готовые, автоматизированные и с умеренным риском стратегии для Middle
- обучающие курсы для категории middle.
- во взаимодействии с аудиторией групп middle и big будут преобладать прямой стиль, цифры, конкретные результаты.

Проверять успешность внедряемых инициатив можно при помощи A/B тестирования внедрения новых продуктов (CTR реклам, обучающих курсов) . Можно попробовать обе стратегии, в итоге следует оценить LTV по половому признаку, для определения наиболее действенной стратегии.

Распределение gain по education

Part 2.2

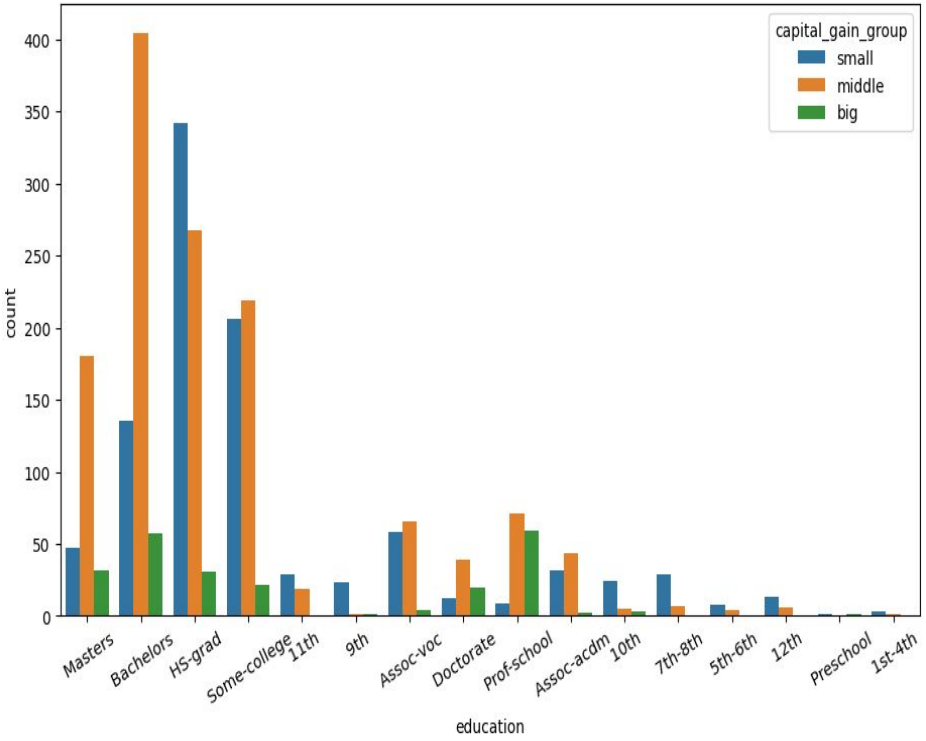

Но нет связи между уровнем образования и капитальным доходом

H1 существует связь: более образованные люди имеют более высокий капитальный доход

- Используем тест Крускала
- Оцениваем результат

Бизнес выводы: Part 2.2

1. Люди с высшим и поствысшим образованием: значительно чаще попадают в middle и big, тогда как доля small заметно ниже.
2. Люди без завершённого среднего:почти полностью сосредоточены в small крайне редко достигают крупных капитальных доходов
3. Образование работает как фильтр доступа к инструментам, навыкам и возможностям инвестирования.

Постановка бизнес-задачи Part 2.3 Егор Виталя

Банкам необходимо по косвенным факторам определить LTV каждого клиента.

- Если клиент - корпоративный бизнес, то банк получает много выгоды от сотрудничества с ним из-за объема банковских продуктов для него

Задача: используя данные из датасета (пол, раса, образование, статус и тд) определить самые лучшие “демографии” клиентов и оценить какие факторы положительно влияют на вероятность клиента вырасти в корп. бизнес

Part 2.3 Егор Виталя

H0: доля корп-бизнесов одинаков для обоих полов

H1: доля мужчин владельцев корп-бизнесов выше

Тест: Хи-квадрат

(тк сравниваем доли и рассматриваем категориальные і

Результаты: pvalue > 0.05

=> отрицаем нулевую гипотезу, берем альтернативную

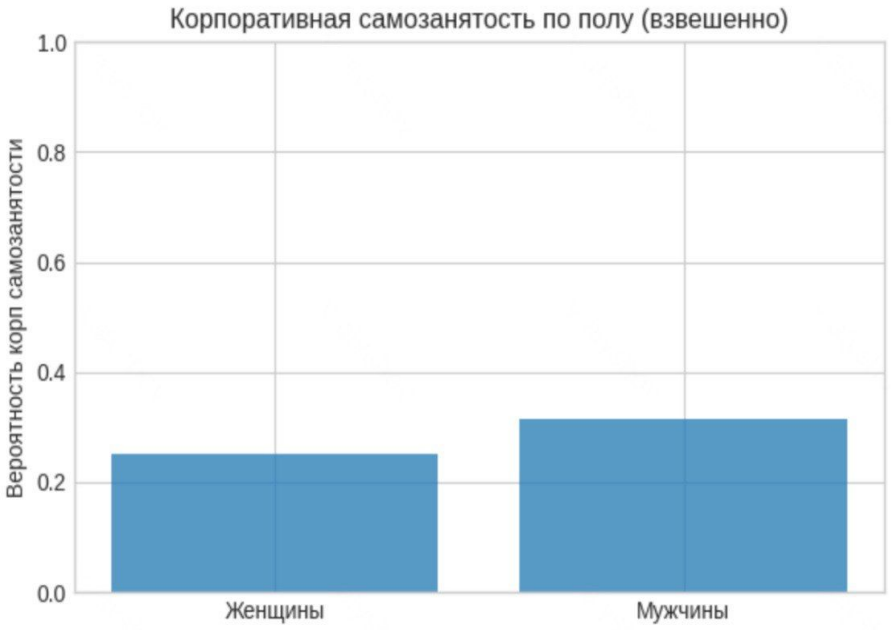

Part 2.3

H0: доля корп-бизнесов одинакова среди инвесторов с 0/>0 доходом

H1: доля корп-бизнесов выше среди инвесторов с >0 доходом

Тест: Хи-квадрат

(тк сравниваем доли и рассматриваем категориальные признаки

Результаты: pvalue > 0.05

=> отрицаем нулевую гипотезу, берем альтернативную

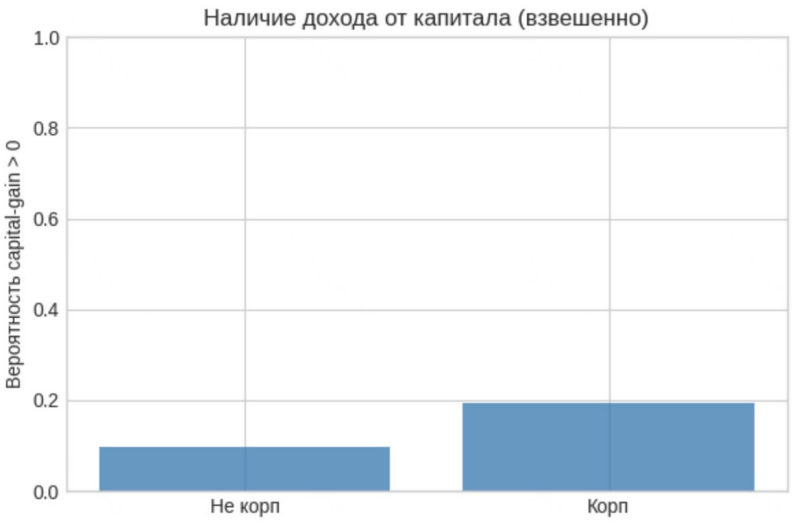

Part 2.3

H0: доля корп-бизнесов одинакова распредена по образованию

H1: доля корп-бизнесов зависит от уровня образования

Тест: Хи-квадрат

(тк сравниваем доли и рассматриваем категориальные признаки)

Результаты: pvalue < 0.05

=> отрицаем нулевую гипотезу, берем альтернативную

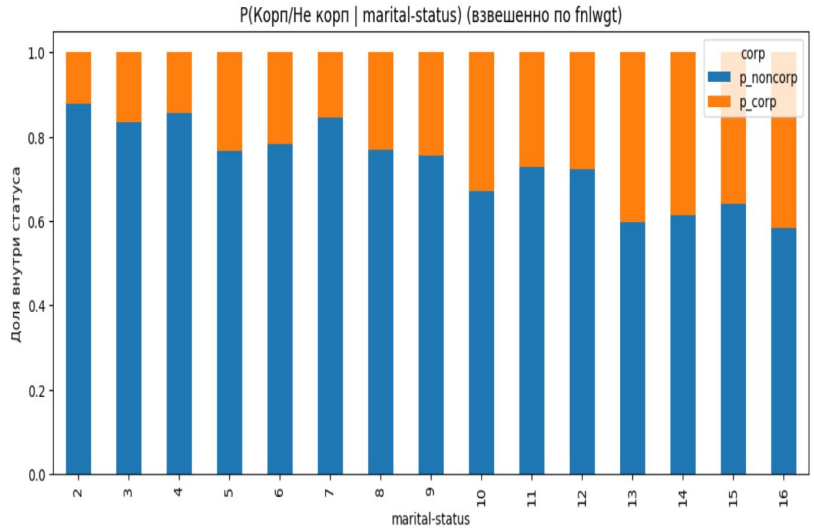

Part 2.3

H0: доля корп-бизнесов одинакова среди людей с разным marital-status

H1: доля корп-бизнесов **зависит** от marital-status

Тест: Хи-квадрат

(тк сравниваем доли и рассматриваем категориальные признаки)

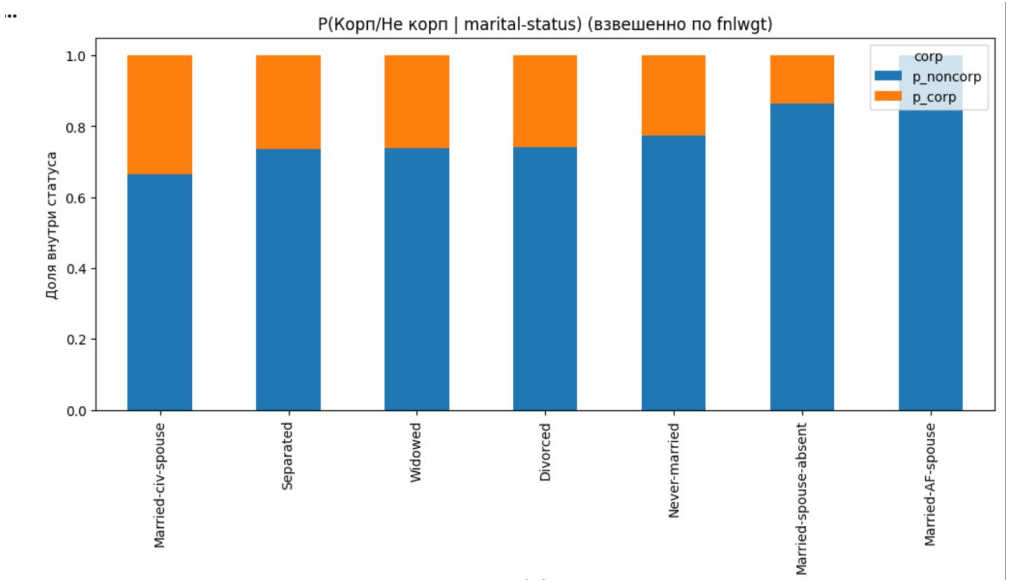

Результаты: pvalue < 0.05

=> отрицаем нулевую гипотезу, берем альтернативную

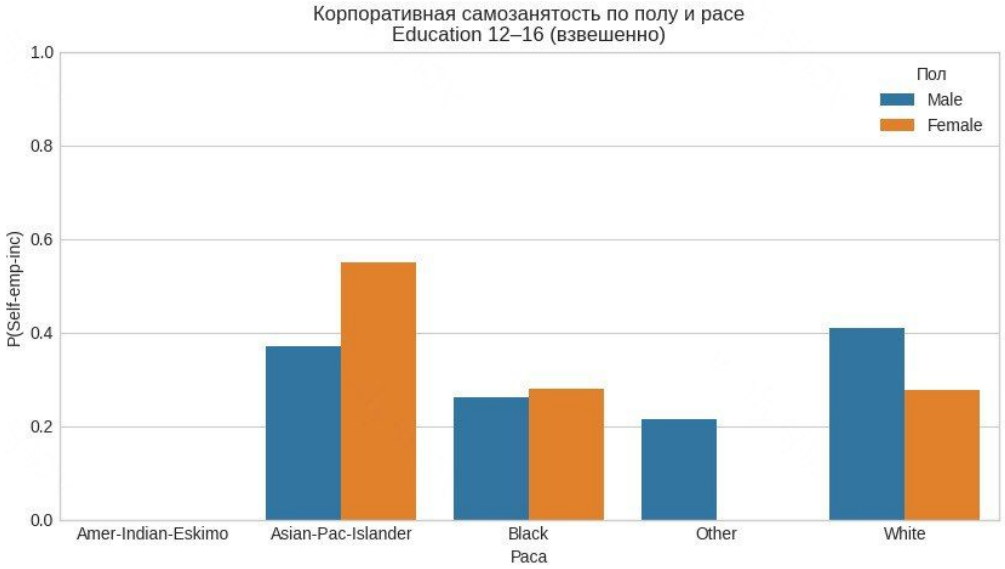

Можно заметить, что доля азиатских и черных женщин корпоративных клиентов выше, чем аналогичных мужчин (при высоком уровне образования)

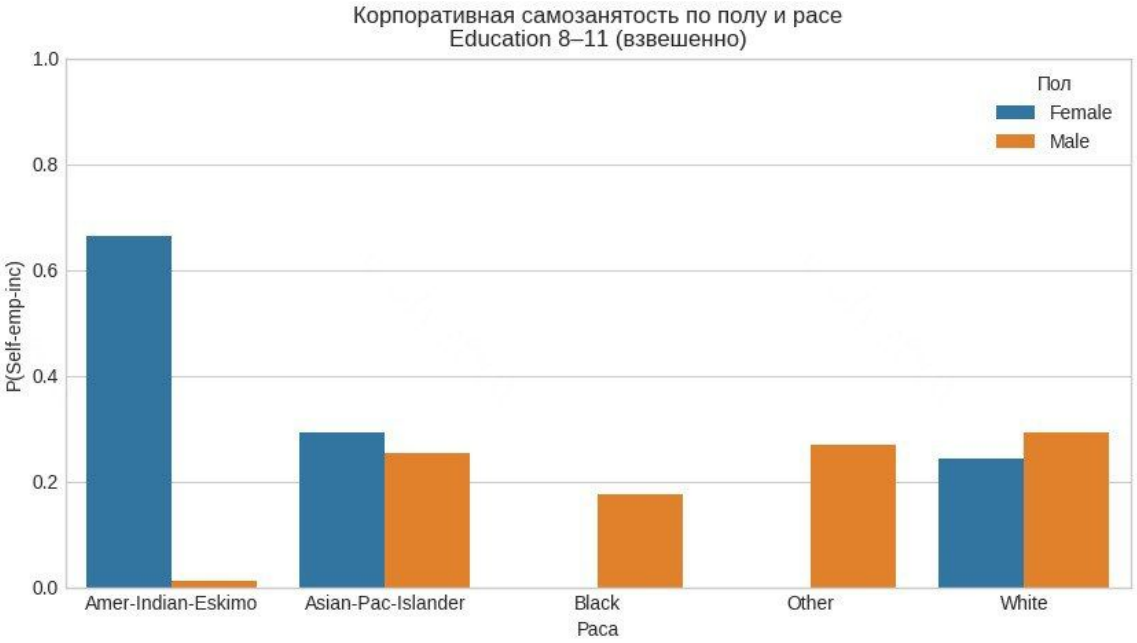

Можно заметить, что для уровней образования ниже бакалавриата особых различий для рас нет(различия в пару процентов). Есть выброс для американских индейцев, но их не очень много.

Бизнес-выводы

- Самые высокие демографии по доле корпов:
  - Белые женатые мужчины с уровнями образования бакалавриат, старшая школа, колледж имеют самый большой (с отрывом) процент корпоративного бизнеса и некорпоративного бизнеса
- Если человек женится рано, то у него меньше шансов стать именно корпоративным бизнесом
- У белых клиентов как правило доля мужчин с корп бизнесом на 25-100% выше, чем у женщин
- Доля азиатских и черных женщин корпоративных клиентов выше, чем аналогичных мужчин (при высоком уровне образования)

Итоги.

Реализован анализ развития бизнеса в трёх различных направлениях.

Повышение внутренней эффективности за счёт внедрения HR - стратегий.

Повышение прибыльности за счёт изменения маркетинговой стратегии по половому признаку, уровню образования и возрасту.

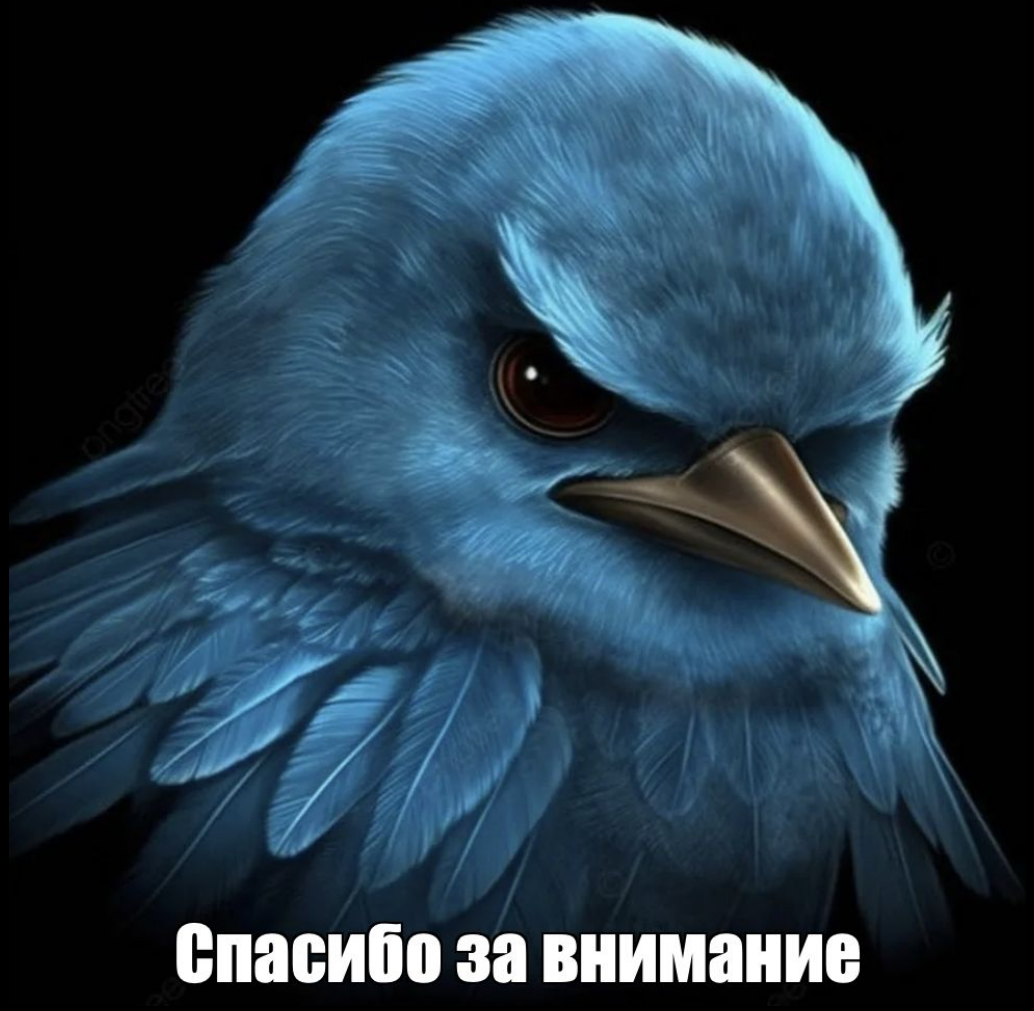

Спасибо за внимание